Μάθημα	**Ανάλυση Δεδομένων μεγάλου Όγκου (Big Data)**
Αριθμός Εργασίας	Δεύτερη Ομαδική εργασία
Είδος εργασίας	**Υποχρεωτική**
Μορφή Υλοποίησης	**Ομαδική** (1 έως και 2 άτομα)
Ημερομηνία Παράδοσης	**Παρασκευή 9 Ιανουαρίου 2026 23:59** (Δε θα δοθεί παράταση)
Παράδοση εργασίας	**e-class**

Ανάλυση Αποχωρήσεων Πελατών (Customer Churn) σε Τηλεπικοινωνιακό Πάροχο με χρήση Apache Spark

Περιγραφή Προβλήματος

Στόχος είναι η ανάλυση δεδομένων αποχωρήσεων πελατών (customer churn) τηλεπικοινωνιακού παρόχου, χρησιμοποιώντας το Apache Spark. Θα αξιοποιηθεί το dataset telecom_churn_10k.csv, το οποίο περιλαμβάνει πληροφορίες για πελάτες, συμβόλαια και χρήση υπηρεσιών. Κάθε εγγραφή περιέχει πεδία όπως: CUSTOMER_ID, AGE, COUNTRY, TENURE_MONTHS, CONTRACT_TYPE, HAS_INTERNET, HAS_MOBILE, HAS_TV, MONTHLY_CHARGES, TOTAL_CHARGES, NUM_COMPLAINTS, SUPPORT_CALLS, PAYMENT_METHOD, CHURN. Οι φοιτητές καλούνται να υλοποιήσουν ανάλυση με **Spark DataFrame API** και **Spark SQL**, να διαχειριστούν ελλιπή δεδομένα και να κατασκευάσουν ένα μοντέλο μηχανικής μάθησης με **Spark ML**, σε σενάριο παλινδρόμησης (πρόβλεψη MONTHLY_CHARGES) βασισμένο σε χαρακτηριστικά πελατών και συμβολαίων.

Hint (για να "σκεφτείτε επιχειρησιακά")

- Πελάτες με πλήρες πακέτο υπηρεσιών (Internet + κινητή + TV) και μεγάλη διάρκεια συνεργασίας τείνουν συνήθως να έχουν χαμηλότερο ποσοστό αποχωρήσεων.
- Πελάτες με μόνο κινητή υπηρεσία και συμβόλαιο τύπου *Month-to-month* εμφανίζουν συχνά αυξημένο κίνδυνο churn (αποχώρησης).
- Συνδυασμός πολλών παραπόνων, συχνών κλήσεων στο support και υψηλών μηνιαίων χρεώσεων μπορεί να λειτουργεί ως «σήμα κινδύνου» για αποχώρηση.

Οι αναλύσεις και τα μοντέλα σας θα πρέπει να ελέγξουν αν τα παραπάνω επιβεβαιώνονται στα δεδομένα.

Περιγραφή δεδομένων

Για την παρούσα εργασία θα χρησιμοποιηθεί το αρχείο telecom_churn_10k.csv, το οποίο περιέχει δεδομένα πελατών τηλεπικοινωνιακού παρόχου (10.000 γραμμές). Κάθε γραμμή του αρχείου αντιστοιχεί σε έναν πελάτη και περιλαμβάνει βασικές πληροφορίες σχετικά με τα δημογραφικά χαρακτηριστικά, τον τύπο συμβολαίου, τις ενεργές υπηρεσίες, τη χρέωση, τη δυσαρέσκεια και το αν ο πελάτης έχει αποχωρήσει από τον πάροχο. Μπορείτε να κατεβάσετε το αρχείο από το ακόλουθο link.
Το αρχείο telecom_churn_10k.csv περιέχει εγγραφές πελατών με τα ακόλουθα πεδία:

- **CUSTOMER_ID**: Μοναδικό αναγνωριστικό πελάτη. Χρησιμοποιείται για ταυτοποίηση εγγραφών και για τυχόν ομαδοποιήσεις ανά πελάτη.
- **GENDER**: Φύλο πελάτη (Male/Female). Μπορεί να χρησιμοποιηθεί για ανάλυση διαφορών στη συμπεριφορά αποχώρησης ανά φύλο.
- **AGE**: Ηλικία πελάτη σε έτη. Επιτρέπει ανάλυση churn ανά ηλικιακή ομάδα. Περιλαμβάνει ορισμένες ελλιπείς τιμές που πρέπει να διαχειριστούν.
- **COUNTRY**: Χώρα ή περιοχή του πελάτη (π.χ. GR, DE, UK). Χρησιμοποιείται για γεωγραφική ανάλυση εσόδων και αποχωρήσεων.
- **TENURE_MONTHS**: Διάρκεια συνεργασίας σε μήνες. Κεντρικό πεδίο για μελέτη της σχέσης μεταξύ «παλαιότητας» πελάτη και πιθανού churn. Περιλαμβάνει ελλιπείς τιμές.

- **CONTRACT_TYPE:** Τύπος συμβολαίου (Month-to-month, One year, Two year). Χρησιμοποιείται για σύγκριση ρυθμών αποχώρησης ανά είδος συμβολαίου.
- **HAS_INTERNET**: Δείκτης αν ο πελάτης έχει υπηρεσία Internet (0/1).
- **HAS_MOBILE**: Δείκτης αν ο πελάτης έχει κινητή τηλεφωνία (0/1).
- **HAS_TV**: Δείκτης αν ο πελάτης έχει υπηρεσία TV/Streaming (0/1).
- **MONTHLY_CHARGES**: Μηνιαία χρέωση σε €. Βασικό πεδίο για ανάλυση της σχέσης τιμής–churn. Περιλαμβάνει ορισμένες ελλιπείς τιμές.
- **TOTAL_CHARGES**: Συνολικές χρεώσεις από την αρχή της συνεργασίας. Χρησιμοποιείται για αποτύπωση συνολικής αξίας πελάτη (customer value) και περιλαμβάνει ελλιπείς τιμές.
- **NUM_COMPLAINTS**: Αριθμός καταγεγραμμένων παραπόνων. Σχετίζεται με τη δυσαρέσκεια πελάτη και μπορεί να επηρεάζει το churn.
- **SUPPORT_CALLS**: Αριθμός κλήσεων στο τμήμα υποστήριξης. Μπορεί να συνδυαστεί με NUM_COMPLAINTS για εντοπισμό «προβληματικών» περιπτώσεων.
- **PAYMENT_METHOD**: Τρόπος πληρωμής (Credit card, Bank transfer, Cash, E-banking). Επιτρέπει ανάλυση προτιμήσεων πληρωμής και συσχέτιση με churn.
- **CHURN**: Μεταβλητή–στόχος, ένδειξη αν ο πελάτης έχει αποχωρήσει από τον πάροχο (1 = αποχώρηση, 0 = ενεργός πελάτης). Περιλαμβάνει επίσης ορισμένες ελλιπείς τιμές, οι οποίες πρέπει να αντιμετωπιστούν προσεκτικά πριν την εκπαίδευση μοντέλων.

Σε αρκετά από τα παραπάνω πεδία (AGE, TENURE_MONTHS, MONTHLY_CHARGES, TOTAL_CHARGES, CHURN) έχουν εισαχθεί εσκεμμένα ελλιπείς τιμές (missing values), ώστε να απαιτείται ρητή φάση καθαρισμού και τεκμηριωμένη επιλογή στρατηγικής διαχείρισής τους στο πλαίσιο της εργασίας.

Θέμα 1: Φόρτωση, Έλεγχος και Καθαρισμός Δεδομένων (3 βαθμοί)

1. **Δημιουργία DataFrame**
   - Δημιουργήστε νέο notebook (π.χ. σε Google Colab) και αρχικοποιήστε SparkSession.
   - Φορτώστε το αρχείο telecom_churn_10k.csv σε Spark DataFrame, με header=True, inferSchema=True.
   - Εμφανίστε:
     - τις πρώτες 10 γραμμές (df.show(10)),
     - το σχήμα (df.printSchema()),
     - και τον συνολικό αριθμό εγγραφών (df.count()).
2. **Έλεγχος ελλιπών τιμών (missing values)**
   - Υπολογίστε, για κάθε στήλη, πόσες ελλιπείς τιμές υπάρχουν (null/NaN).
   - Παρουσιάστε συγκεντρωτικά τα αποτελέσματα (π.χ. DataFrame με στήλες: column_name, missing_count).
   - Εστιάστε ειδικά στα πεδία: AGE, TENURE_MONTHS, MONTHLY_CHARGES, TOTAL_CHARGES, CHURN και σχολιάστε σύντομα ποια από αυτά επηρεάζουν περισσότερο την ανάλυση.
3. **Στρατηγική καθαρισμού**
   - Ορίστε και εφαρμόστε μία συγκεκριμένη στρατηγική καθαρισμού, η οποία να περιλαμβάνει **τουλάχιστον**:
     - χειρισμό των ελλιπών τιμών στο CHURN (π.χ. αφαίρεση των αντίστοιχων γραμμών),
     - χειρισμό των ελλιπών τιμών σε αριθμητικά πεδία (AGE, TENURE_MONTHS, MONTHLY_CHARGES, TOTAL_CHARGES) με απλή, αλλά τεκμηριωμένη προσέγγιση (π.χ. mean/median/most frequent).

- Τεκμηριώστε σε σχόλιο/Markdown ποια στρατηγική επιλέξατε και γιατί (min 2 προτάσεις).

4. **Βασική περιγραφική ανάλυση**
   - Υπολογίστε βασικά στατιστικά (π.χ. describe() ή summary()) για τις στήλες: AGE, TENURE_MONTHS, MONTHLY_CHARGES, TOTAL_CHARGES.
   - Προαιρετικά, υπολογίστε μέσο όρο TENURE_MONTHS και MONTHLY_CHARGES ξεχωριστά για CHURN = 0 και CHURN = 1.
   - Σχολιάστε σε 3–4 προτάσεις τι παρατηρείτε (π.χ. αν οι πελάτες που αποχωρούν έχουν μικρότερο tenure ή/και υψηλότερες χρεώσεις).
5. **Αρχικό Feature Engineering**
   - Δημιουργήστε τουλάχιστον **δύο (2)** νέα πεδία που θα φανούν χρήσιμα στα επόμενα θέματα, π.χ.:
     - NUM_SERVICES = HAS_INTERNET + HAS_MOBILE + HAS_TV,
     - AVG_CHARGE_PER_MONTH = TOTAL_CHARGES/ TENURE_MONTHS (με προσοχή σε μηδενικό tenure),
     - ή binary ένδειξη όπως IS_LONG_TENURE (1 αν TENURE_MONTHS >= 24, αλλιώς 0).
   - Εμφανίστε δείγμα γραμμών με τις νέες στήλες (select(...).show()).

Παράδοση: Αποσπάσματα κώδικα και αποτελεσμάτων στο notebook (πίνακας με missing values, output από τα βασικά στατιστικά, δείγμα του "καθαρού" DataFrame με τα νέα πεδία), καθώς και σύντομος σχολιασμός των επιλογών καθαρισμού και των αρχικών παρατηρήσεων.

Θέμα 2: Ανάλυση με Spark SQL & Επιβεβαίωση Επιχειρησιακών Μοτίβων (3 βαθμοί)

Σε αυτό το θέμα θα χρησιμοποιήσετε **Spark SQL** πάνω στο «καθαρό» DataFrame που προέκυψε από το Θέμα 1.

1. **Δημιουργία προσωρινού view**
   - Χρησιμοποιήστε το καθαρισμένο DataFrame (μετά τον χειρισμό των missing values και τη δημιουργία των νέων πεδίων, π.χ. NUM_SERVICES, IS_LONG_TENURE κ.λπ.).
   - Δημιουργήστε ένα temporary view, π.χ. df_clean.createOrReplaceTempView("churn_view").
2. **Βασικά ερωτήματα ανάλυσης churn**
   Υλοποιήστε τουλάχιστον τα παρακάτω ερωτήματα σε **Spark SQL** και εμφανίστε τα αποτελέσματα:

   2.1. **Churn ανά τύπο συμβολαίου**
   - Υπολογίστε για κάθε CONTRACT_TYPE:
     - συνολικό πλήθος πελατών,
     - πλήθος πελατών με CHURN = 1,
     - ποσοστό churn (%).
   - Ταξινομήστε κατά φθίνουσα σειρά ποσοστού churn.

   2.2. **Churn ανά πλήθος υπηρεσιών**
   - Χρησιμοποιήστε το πεδίο NUM_SERVICES (ή αντίστοιχο που δημιουργήσατε) και υπολογίστε:
     - ποσοστό churn για πελάτες με 1, 2 και ≥3 υπηρεσίες.

   2.3. **Churn και μηνιαία χρέωση**
   - Υπολογίστε τη μέση τιμή MONTHLY_CHARGES ξεχωριστά για:
     - CHURN = 0
     - CHURN = 1

- Προαιρετικά, ομαδοποιήστε και ανά CONTRACT_TYPE (π.χ. μέσο MONTHLY_CHARGES για churners/non-churners ανά τύπο συμβολαίου).

3. **Γεωγραφική ανάλυση (Top-X περιοχές)**
   - Υπολογίστε, για κάθε COUNTRY:
     - πλήθος πελατών,
     - ποσοστό churn.
   - Διατηρήστε μόνο χώρες με τουλάχιστον **100 πελάτες**.
   - Εμφανίστε τις **Top-5** χώρες με το υψηλότερο ποσοστό churn, ταξινομημένες κατά φθίνουσα σειρά.
4. **Έλεγχος των Hints του προβλήματος**

Με βάση τα αποτελέσματά σας από τα παραπάνω queries:

- Σχολιάστε αν:
  - οι πελάτες με **Month-to-month** συμβόλαιο έχουν πράγματι υψηλότερο churn σε σχέση με **One year / Two year**,
  - οι πελάτες με **πολλαπλές υπηρεσίες** (π.χ. NUM_SERVICES ≥ 3) εμφανίζουν χαμηλότερο churn σε σχέση με όσους έχουν μόνο 1 υπηρεσία,
  - οι πελάτες με υψηλότερες MONTHLY_CHARGES τείνουν να έχουν αυξημένο churn.
- Ο σχολιασμός να γίνει σε **σύντομο κείμενο 8-10 προτάσεων** (Markdown cell στο notebook), όπου θα συνδέετε ρητά τα αριθμητικά αποτελέσματα των ερωτημάτων σας με τα επιχειρησιακά συμπεράσματα.

Παράδοση:

- Ο κώδικας δημιουργίας του churn_view.
- Τα SQL queries (σε spark.sql("...")) και τα αντίστοιχα αποτελέσματα (show()).
- Ένας πίνακας/προβολή με τα Top-5 countries κατά ποσοστό churn.
- Σύντομος, καθαρός σχολιασμός που να απαντά ευθέως: *«επιβεβαιώνονται/δεν επιβεβαιώνονται τα hints και γιατί»*.

Θέμα 3: Πρόβλεψη Μηνιαίας Χρέωσης με Decision Tree για δυναμική τιμολόγηση (4 βαθμοί)

Στο Θέμα αυτό θα υλοποιήσετε ένα απλό μοντέλο παλινδρόμησης (regression) σε Apache Spark ML, με στόχο την πρόβλεψη της μηνιαίας χρέωσης πελάτη (MONTHLY_CHARGES), χρησιμοποιώντας ως είσοδο δημογραφικά στοιχεία, τύπο συμβολαίου και πληροφορίες υπηρεσιών.

Σε επιχειρησιακό επίπεδο, μας ενδιαφέρει να μπορούμε να εκτιμήσουμε ποια θα είναι η **αναμενόμενη μηνιαία χρέωση** για έναν πελάτη, δεδομένου του προφίλ του (ηλικία, χώρα, διάρκεια συνεργασίας) και των υπηρεσιών/συμβολαίου που επιλέγει.

Ένα τέτοιο μοντέλο μπορεί να χρησιμοποιηθεί για:

- απλές προσομοιώσεις "what–if" (π.χ. τι θα πληρώνει αν προσθέσει υπηρεσία TV ή αν αλλάξει από Month-to-month σε Two year),
- υποστήριξη τιμολογιακής πολιτικής και σχεδιασμό προσφορών για συγκεκριμένες κατηγορίες πελατών.

Χρησιμοποιείτε **το καθαρισμένο DataFrame** που προέκυψε από το Θέμα 1 (χωρίς missing values στα πεδία που θα χρησιμοποιηθούν).

1. **Ορισμός συνόλου χαρακτηριστικών (features) και στόχου (label)**
   - Ορίστε ως μεταβλητή-στόχο (label) το πεδίο:
     - MONTHLY_CHARGES. Το μοντέλο που θα χτίσετε θα προβλέπει την αναμενόμενη τιμή του μηνιαίου λογαριασμού για έναν νέο ή υπάρχοντα πελάτη, με βάση τα επιλεγμένα χαραχτηριστικά.
   - Επιλέξτε ως features τουλάχιστον τα παρακάτω πεδία:

        - AGE, TENURE_MONTHS, NUM_COMPLAINTS, SUPPORT_CALLS
        - HAS_INTERNET, HAS_MOBILE, HAS_TV, NUM_SERVICES (αν το έχετε δημιουργήσει)
        - CONTRACT_TYPE, PAYMENT_METHOD, COUNTRY
    - Δημιουργήστε ένα νέο DataFrame που να περιέχει μόνο τα παραπάνω features και το MONTHLY_CHARGES ως label.
2. **Προεπεξεργασία & Pipeline**
    - Κάντε index στα κατηγορικά πεδία (π.χ. CONTRACT_TYPE, PAYMENT_METHOD, COUNTRY) με StringIndexer.
    - (Προαιρετικά) Χρησιμοποιήστε OneHotEncoder για τα indexed πεδία.
    - Συνδυάστε όλα τα αριθμητικά και κατηγορικά features σε ένα διάνυσμα εισόδου με VectorAssembler (στήλη features).
    - Ορίστε ένα DecisionTreeRegressor με labelCol="MONTHLY_CHARGES" και featuresCol="features".
    - Δημιουργήστε ένα Pipeline που περιλαμβάνει: indexers → (encoder) → assembler → decision tree regressor.
3. **Εκπαίδευση και αξιολόγηση**
    - Χωρίστε τα δεδομένα σε train/test (π.χ. 70% / 30% με σταθερό random seed).
    - Εκπαιδεύστε το μοντέλο στο training set και παράγετε προβλέψεις στο test set.
    - Υπολογίστε τουλάχιστον τις μετρικές:
        - **RMSE (Root Mean Squared Error)**
        - **R^2 (coefficient of determination)**
    - Εμφανίστε τις τιμές των μετρικών και σχολιάστε σε 3–4 προτάσεις πόσο «λογικές» είναι σε σχέση με τα μεγέθη των λογαριασμών (π.χ. αν ο μέσος λογαριασμός είναι 40–50€ και το RMSE είναι 15€, τι σημαίνει αυτό επιχειρησιακά;).

Παράδοση:
Στο notebook θα πρέπει να φαίνονται:

- Ο καθορισμός του συνόλου features + label και η δημιουργία του κατάλληλου DataFrame.
- Ο ορισμός και η υλοποίηση του Spark ML Pipeline (indexers, assembler, DecisionTreeRegressor).
- Ο κώδικας train/test split, η εκπαίδευση του μοντέλου και η παραγωγή προβλέψεων.
- Οι τιμές των μετρικών RMSE και R^2 για το test set.
- Σύντομος σχολιασμός (Markdown) που να εξηγεί αν το μοντέλο είναι «χονδρικά χρήσιμο» ή αν τα σφάλματα είναι πολύ μεγάλα για να υποστηρίξουν πρακτική τιμολόγηση/πρόβλεψη λογαριασμών.

Οδηγίες & Παραδοτέα

1) Γλώσσα / Περιβάλλον

a. Υλοποίηση σε **PySpark** (Python 3.x, Spark 3.x).

b. Επιτρέπεται εναλλακτικά **Scala/Spark**, εφόσον τηρηθεί η ίδια λογική θεμάτων και παράγονται αντίστοιχα αποτελέσματα.

c. Επιτρεπόμενα περιβάλλοντα: **Google Colab / Jupyter Notebook / τοπική εγκατάσταση Spark**.

- Προτεινόμενο για ευκολία: **Google Colab**.

2) Τι παραδίδετε (όλα σε ένα .zip)

a. Κώδικας

i. Αρχείο notebook με την υλοποίηση όλων των θεμάτων, π.χ.: telecom_churn_hw2.ipynb

- Σε περίπτωση Colab, να γίνει **export σε .ipynb** και να συμπεριληφθεί στο .zip.

- Αν δουλέψατε εκτός notebook, παραδώστε αντίστοιχα .py ή .scala αρχεία, με σαφή δομή.

ii. Αν υπάρχουν βοηθητικά modules, scripts ή αρχεία:
- Φάκελος src/
- και σύντομο README με οδηγίες εκτέλεσης (πώς τρέχει ο κώδικας, σε ποια σειρά).

b. Αποτελέσματα

i. Δεν είναι υποχρεωτικό να αποθηκεύσετε ενδιάμεσα δεδομένα σε CSV.
- Ωστόσο, αν επιλέξετε να εξάγετε αποτελέσματα (π.χ. πίνακες από Spark SQL) σε αρχεία, τοποθετήστε τα σε φάκελο out/ μέσα στο .zip (π.χ. out/top5_churn_countries.csv).

ii. Τα αποτελέσματα των θεμάτων πρέπει να είναι **ορατά μέσα στο notebook**:
- πίνακες από show() για τα ερωτήματα SQL του Θέματος 2,
- βασικά στατιστικά του Θέματος 1,
- μετρικές RMSE / R^2 του μοντέλου στο Θέμα 3,
- καθώς και τα σχόλια/ερμηνείες σε Markdown cells.

c. Αναφορά (PDF, έστω 2 σελίδες)

Σύντομη αναφορά που θα περιλαμβάνει:

i. Περιγραφή και καθαρισμό δεδομένων (Θέμα 1):
- ποια πεδία έχουν missing values,
- ποια στρατηγική ακολουθήσατε για τη διαχείρισή τους.

ii. Βασικά ευρήματα από την ανάλυση με Spark SQL (Θέμα 2):
- ποσοστά churn ανά τύπο συμβολαίου, αριθμό υπηρεσιών, χώρα,
- και αν/πώς επιβεβαιώνονται τα “hints” του προβλήματος.

iii. Σύνοψη του μοντέλου παλινδρόμησης (Θέμα 3):
- τι features χρησιμοποιήθηκαν,
- τι τιμές είχαν οι μετρικές (RMSE, R^2),
- αν το σφάλμα θεωρείται λογικό σε σχέση με τα ποσά των λογαριασμών.

iv. Οποιαδήποτε απλή οπτικοποίηση χρησιμοποιήσατε (π.χ. ένα bar chart ή πίνακα σύνοψης) με σύντομο σχολιασμό.
- Δεν είναι υποχρεωτικό να δημιουργήσετε περίπλοκα γραφήματα, αρκεί ένα–δύο απλά visuals με ξεκάθαρο σχόλιο.

d. (Προαιρετικά)

Αρχείο requirements.txt ή environment.yml **μόνο αν** χρησιμοποιήσατε πρόσθετες βιβλιοθήκες πέρα από PySpark / τυπικές Python libs (π.χ. extra plotting, κ.λπ.).

3) Κανόνες εκτέλεσης / καλές πρακτικές

a. Ορίστε **σταθερό random seed** όπου έχει νόημα (π.χ. στο train/test split του Θέματος 3), ώστε τα αποτελέσματα να είναι αναπαραγώγιμα.

b. Μην χρησιμοποιείτε collect() σε μεγάλα DataFrames χωρίς λόγο.
- Για έλεγχο αποτελεσμάτων χρησιμοποιήστε show() με περιορισμένο αριθμό γραμμών.

c. Αν τρέχετε το notebook σε Colab ή τοπικά, αναφέρετε στην αναφορά (ή σε Markdown cell) το περιβάλλον εκτέλεσης:
- CPU / RAM (ενδεικτικά),
- εκδόσεις Python / Spark.

d. Φροντίστε το notebook να εκτελείται από πάνω προς τα κάτω **χωρίς σφάλματα**, με λογική σειρά κελιών (Θέμα 1 → Θέμα 2 → Θέμα 3).

4) Ονοματοδοσία & Υποβολή

a. Όνομα αρχείου .zip:

uom_bigdata_2025_hw2_<Surname1_Surname2>.zip
(ή ένα επίθετο αν η ομάδα έχει ένα μόνο μέλος).
b. Υποβολή ηλεκτρονικά στο e-class μέχρι την καταληκτική ημερομηνία.
- Μία υποβολή ανά ομάδα.

c. Οι ομάδες θα δηλωθούν σε ξεχωριστή διαδικασία (φόρμα / αρχείο) μέχρι συγκεκριμένη ημερομηνία που θα ανακοινωθεί (π.χ. μία εβδομάδα πριν την υποβολή).

5) Ακεραιότητα / Αναπαραγωγιμότητα

a. Η εργασία είναι ομαδική (1–2 άτομα).
- Δηλώστε **ονόματα και ΑΜ** στην αρχή του notebook και στην αναφορά (π.χ. σε ένα header section).

b. Ο κώδικας πρέπει να μπορεί να τρέξει χωρίς αλλαγές σε paths:
- χρησιμοποιείτε relative paths,
- μην περνάτε ρητά προσωπικά paths (π.χ. /home/user/..., C:\Users\...).

c. Αναφέρετε ρητά **οποιαδήποτε εξωτερική πηγή** χρησιμοποιήθηκε (κώδικας, ιδέες, εργαλεία AI όπως ChatGPT, BlackBox AI κ.λπ.) και **πώς** τη χρησιμοποιήσατε (π.χ. "χρησιμοποιήθηκε για βοήθεια στη διατύπωση SQL queries").

d. Αν υπήρξε συνεργασία/συζήτηση με άλλη ομάδα (π.χ. κοινές ιδέες ή debugging), αναφέρετέ το συνοπτικά.

- Το τελικό notebook και τα αποτελέσματα πρέπει να είναι προϊόν **αυτόνομης υλοποίησης** της ομάδας σας.

Ενδεικτικές Αναφορές

[1] Διαλέξεις, σημειώσεις και ασκήσεις μαθήματος.
[2] **Spark SQL** is Apache Spark's module for working with structured data
[3] Decision trees MLib Spark
[4] PySpark Decision Tree, How to Build and Evaluate Decision Tree Model for Classification using PySpark MLlib