ΠΑΝΕΠΙΣΤΗΜΙΟ ΜΑΚΕΔΟΝΙΑΣ
ΤΜΗΜΑ ΕΦΑΡΜΟΣΜΕΝΗΣ ΠΛΗΡΟΦΟΡΙΚΗΣ

# Αναφορά 1ης εργασίας
# –
# Classification Problem

ΜΑΘΗΜΑ: ΜΗΧΑΝΙΚΗ ΜΑΘΗΣΗ

ΑΠΟΣΤΟΛΟΣ ΣΙΝΙΟΡΗΣ(ics24123)
ΕΠΙΒΛΕΠΩΝ ΚΑΘΗΓΗΤΗΣ: ΕΥΤΥΧΙΟΣ ΠΡΩΤΟΠΑΠΑΔΑΚΗΣ

# Πίνακας περιεχομένων

Πίνακας εικόνων ..... 2
Εισαγωγή ..... 3
Περιγραφή των δεδομένων – DataSet ..... 4
Θεωρητικό υπόβαθρο ..... 5
Διαχείριση δεδομένων με τη Βιβλιοθήκη Pandas ..... 5
Γραφήματα με την βιβλιοθήκη Matplotlib ..... 5
Διαχωρισμός των δεδομένων με τον αλγόριθμο Stratified K-Fold ..... 5
Linear Discriminant Analysis (LDA) ..... 6
Logistic Regression ..... 6
Decision Trees ..... 6
Random Forests ..... 6
K-Nearest Neighbors ..... 7
Naïve Bayes ..... 7
Support Vector Machines (SVM) ..... 7
Gradient Boosting Classifier ..... 8
Πειραματικά Αποτελέσματα ..... 8
Figure 1: Πλήθος υγιών vs Χρεοκοπημένων Εταιρειών ανά έτος ..... 8
Figure 2a: Στατιστικά (Min, Mean, Max) για Υγιείς Επιχειρήσεις ..... 9
Figure 2b: Στατιστικά (Min, Mean, Max) για Χρεωκοπημένες Επιχειρήσεις ..... 10
Pivot Table από την ανάλυση που έγινε στο Excel ..... 10
Συγκριτικός πίνακας επιδόσεων στο Test Set, με βάση το F1 Score ..... 11
Συγκριτικός πίνακας επιδόσεων με βάση το Recall και το TNR ..... 12
Confusion Matrix για τον αλγόριθμο Gradient Boosting ..... 13
Συμπεράσματα ..... 15
Αναφορές σε ιστοτόπους ..... 16
Βιβλιογραφικές αναφορές ..... 16

## Πίνακας εικόνων

Figure 1: Πλήθος υγιών vs Χρεοκοπημένων Εταιρειών ανά έτος ..... 8
Figure 2a: Στατιστικά (Min, Mean, Max) για Υγιείς Επιχειρήσεις ..... 9
Figure 2b: Στατιστικά (Min, Mean, Max) για Χρεωκοπημένες Επιχειρήσεις ..... 10
Pivot Table από την ανάλυση που έγινε στο Excel ..... 10
Συγκριτικός πίνακας επιδόσεων στο Test Set, με βάση το F1 Score ..... 11
Συγκριτικός πίνακας επιδόσεων με βάση το Recall και το TNR ..... 12
Confusion Matrix για τον αλγόριθμο Gradient Boosting ..... 13

## Εισαγωγή

Στην παρούσα εργασία, καλούμαστε να επιλύσουμε ένα πρόβλημα «ταξινόμησης» (Classification) στην Μηχανική Μάθηση (Machine Learning). Στην ταξινόμηση, διαχωρίζουμε τα δεδομένα σε 2 κατηγορίες, για αυτό και μια εναλλακτική ονομασία είναι «δυαδική ταξινόμηση». Συγκεκριμένα, ο διαχωρισμός γίνεται στις επονομαζόμενες «κλάσεις». Μετά τον διαχωρισμό, σκοπός είναι να δημιουργήσουμε ένα μοντέλο Μηχανικής Μάθησης, το οποίο θα προβλέψει που θα ταξινομηθούν τα δεδομένα σε μία από τις δύο κατηγορίες.

Το πρόβλημα που πραγματεύεται αυτή η εργασία, αφορά πρόβλεψη για εντοπισμό εταιρειών που θα κηρύξουν χρεωκοπία. Οι εταιρείες που δεν κηρύττουν χρεωκοπία είναι Υγιείς. Συνεπώς, μπορούμε από τώρα να κάνουμε τον διαχωρισμό σε κλάσεις. Η πρώτη κλάση είναι οι «Υγιείς» εταιρείες και η δεύτερη είναι οι «Χρεωκοπημένες». Τα δεδομένα που δόθηκαν, περιέχουν ποικίλους χρηματοοικονομικούς δείκτες και δείκτες δραστηριότητας μιας επιχείρησης. Μέσα σε αυτά τα δεδομένα, υπάρχουν ήδη δείκτες για την κατάσταση που βρίσκεται μια εταιρεία σε δεδομένο ημερολογιακό έτος. Δηλαδή, είναι γνωστό εάν μια εταιρεία έχει χρεωκοπήσει ή όχι. Ωστόσο, εμείς θέλουμε με αυτά τα δεδομένα, να κατασκευάσουμε ένα μοντέλο, όπου θα διαβάζει ένα μέρος των δεδομένων, θα εκπαιδεύεται πάνω σε αυτό το κομμάτι και ύστερα θα μπορέσει να μαντέψει για ένα άλλο άγνωστο (για το μοντέλο) κομμάτι δεδομένων, αν οι εταιρείες που βρίσκονται μέσα σε αυτό, πρόκειται να κηρύξουν χρεωκοπία.

Το αποτέλεσμα, που επιθυμούμε, είναι ένα μοντέλο που θα μπορεί σε μεγάλο ποσοστό να κάνει επιτυχείς προβλέψεις. Εάν μια εταιρεία, έχει δείκτες «υγείας», το μοντέλο θα θέλαμε να προβλέψει ότι η εταιρεία δεν θα χρεωκοπήσει, άρα θα είναι «Υγιής». Εάν μια εταιρεία, έχει δείκτες που σηματοδοτούν χρεωκοπία, θα θέλαμε το μοντέλο να δείξει ότι η εταιρεία πρόκειται να χρεωκοπήσει, και άρα να την κατατάξει στην κλάση «Χρεωκοπημένη».

Σε αυτήν την αναφορά, ακολουθεί εκτενής ανάλυση των τρόπων με τους οποίους, κατασκευάστηκε αυτό το μοντέλο Μηχανικής Μάθησης, ενώ ακολουθούν και αποτελέσματα με γραφικές παραστάσεις, ώστε να είναι ευκρινέστερη η αξιολόγηση των αποτελεσμάτων.

## Περιγραφή των δεδομένων – DataSet

Το σύνολο δεδομένων προέρχεται από εξωτερικό αρχείο σε μορφή Excel. Αποτελείται από 10716 εγγραφές (γραμμές) και 13 στήλες. Κάθε εγγραφή αντιπροσωπεύει μία εταιρεία.

Από τις 13 στήλες οι 11 πρώτες (A - K) είναι τα χαρακτηριστικά εισόδου στο μοντέλο μας. Είναι οι ανεξάρτητες μεταβλητές, που περιέχουν χρηματοοικονομικούς δείκτες απόδοσης των εταιρειών και θα τροφοδοτήσουν το μοντέλο μας, ώστε να κάνει τις απαραίτητες ταξινομήσεις.

Η μεταβλητή-στόχος είναι η 12η στήλη, η οποία υποδεικνύει την κατάσταση της εταιρείας. Παίρνει 2 τιμές. Για την κατηγορία «Υγιής» παίρνει την τιμή 1, ενώ για την κατηγορία «Χρεωκοπημένη» παίρνει την τιμή 2. Κατά το στάδιο της προεπεξεργασίας των δεδομένων αυτές οι τιμές μετατράπηκαν σε 0 (Υγιής) και 1 (Χρεωκοπημένη), ώστε να διευκολυνθεί η δυαδική ταξινόμηση.

Η 13η στήλη αναφέρει το έτος καταγραφής των δεδομένων.

Όπως, θα αναφερθεί και παρακάτω, παρατηρείται ότι τα δεδομένα έχουν έντονη ανισοκατανομή για αυτό και θα χρειαστούν τεχνικές εξισορρόπησης και διαχωρισμού, ώστε τα μοντέλα να μπορέσουν να ταξινομήσουν με όσο το δυνατόν λιγότερη μεροληψία στις κλάσεις.

## Θεωρητικό υπόβαθρο

Το μοντέλο υλοποιήθηκε στην γλώσσα Python στο περιβάλλον προγραμματισμού Google Colab. Παρακάτω, αναλύονται τμηματικά τα εργαλεία που χρησιμοποιήθηκαν στην συγγραφή του κώδικα και δίνονται πληροφορίες για το θεωρητικό τους υπόβαθρο.

### Διαχείριση δεδομένων με τη Βιβλιοθήκη Pandas

Η βιβλιοθήκη Pandas [1,2] είναι μια βιβλιοθήκη της γλώσσας Python, για επεξεργασία δεδομένων, με δομές δεδομένων που προσφέρουν υψηλή απόδοση για δεδομένα «μεγάλου όγκου». Στον κώδικα μας, χρησιμοποιήθηκε η δομή DataFrame, η οποία είναι μια δισδιάστατη δομή μεταβλητού μεγέθους σε μορφή πίνακα, με γραμμές και στήλες. Με την βοήθεια κατάλληλων συναρτήσεων, έγινε ανάγνωση των δεδομένων από το αρχείο Excel, έγινε έλεγχος για ύπαρξη κενών τιμών, κανονικοποίηση των δεδομένων στο διάστημα [0,1] αλλά και διαχωρισμός των δεδομένων για να χρησιμοποιηθούν αργότερα σε άλλα σημεία του κώδικα.

### Γραφήματα με την βιβλιοθήκη Matplotlib

Για την καλύτερη κατανόηση των δεδομένων, δημιουργήθηκαν γραφήματα με την βιβλιοθήκη Matplotlib [3,4], μια θεμελιώδη βιβλιοθήκη σχεδίασης στην Python. Συγκεκριμένα, στον κώδικα μας, έγινε δημιουργία ραβδογραμμάτων (Bar charts) για την κατανομή των υγιών και χρεωκοπημένων εταιρειών, την προβολή των ελάχιστων, μέγιστων και μεσαίων τιμών των οικονομικών δεικτών για κάθε κατηγορία, ξεχωριστά. Τέλος, η ίδια βιβλιοθήκη χρησιμοποιήθηκε για την δημιουργία του πίνακα σύγχυσης (Confusion Matrix).

### Διαχωρισμός των δεδομένων με τον αλγόριθμο Stratified K-Fold

Τα δεδομένα λόγω ανισοκατανομής, πριν δοθούν στο μοντέλο για εκπαίδευση και έλεγχο, έπρεπε να διαιρεθούν σε υποσύνολα, όπου κάθε υποσύνολο θα έχει την ίδια αναλογία. Ο αλγόριθμος Stratified K-Fold [5,6], αναλαμβάνει να κάνει αυτή τη διαίρεση σε 4 υποσύνολα (ή αλλιώς folds). Κάθε φορά, τα δεδομένα χωρίζονται, σε training και test sets, ώστε το μοντέλο να εκπαιδευτεί στα γνωστά δεδομένα (training) και να εξεταστεί στα άγνωστα δεδομένα (test). Κάθε τέτοιο fold, έχει ίδιο ποσοστό υγιών και χρεωκοπημένων εταιρειών, ώστε να μην είναι biased (δηλ. να μην μεροληπτεί), υπέρ των υγιών εταιρειών, που είναι περισσότερες.

## Linear Discriminant Analysis (LDA)

Η μέθοδος της Γραμμικής Διακριτικής Ανάλυσης [7], είναι μία μέθοδος που χρησιμοποιείται στην Στατιστική και στοχεύει στην εύρεση ενός γραμμικού συνδυασμού μεταξύ δύο ή περισσότερων κλάσεων. Σκοπός είναι, η προβολή των δεδομένων σε χώρο χαμηλότερων διαστάσεων και ταυτόχρονα γίνεται προσπάθεια μεγιστοποίησης της απόστασης των κλάσεων. Στον κώδικα μας, δεν έχει λάβει κάποια παράμετρο, και δουλεύει ως διαχωριστής για τις 2 κλάσεις που έχουμε στο πρόβλημα.

## Logistic Regression

Είναι αλγόριθμος ταξινόμησης [8], που εκτιμά την πιθανότητα μια εταιρεία να ανήκει στην κλάση της «Χρεωκοπίας» ή στην κλάση της «Υγείας». Χρησιμοποιεί μία σιγμοειδή συνάρτηση (καμπυλοειδής συνάρτηση) και υπολογίζει πιθανότητες μεταξύ 0 και 1, ώστε να κατατάξει τα δεδομένα εισόδου (το σύνολο εκπαίδευσης) σε μία από τις δύο κατηγορίες. Στον κώδικα μας, έχουμε αναθέσει μέγιστο αριθμό επαναλήψεων (max_iter) ίσο με 1000, ώστε να μπορέσει να συγκλίνει, λόγω του μεγάλου όγκου δεδομένων.

## Decision Trees

Τα Δέντρα Αποφάσεων [9] δημιουργούν ένα μοντέλο πρόβλεψης με βάση μια δενδρική δομή. Λειτουργούν με κανόνες (τύπου if-then-else) οι οποίοι εφαρμόζονται πάνω στα δεδομένα εισόδου (train set) και ύστερα ταξινομούν τα δεδομένα στις κατηγορίες. Στον κώδικα μας, έχουμε ορίσει μέγιστο βάθος δέντρου (max_depth) ίσο με 5. Αυτό γίνεται, έτσι ώστε να μην έχουμε over-fitting στα δεδομένα, δηλαδή το δέντρο να μάθαινε σε πολύ μεγάλο βαθμό το test set και να μην μπορούσε να κάνει αργότερα την γενίκευση στα νέα δεδομένα.

## Random Forests

Τα Random Forests [10] είναι μία μέθοδος που περιλαμβάνει τα Decision Trees. Συγκεκριμένα, έχει πολλά Decision Trees όπου κάθε δέντρο εκπαιδεύεται σε τυχαίο/διαφορετικό δείγμα από το σύνολο εκπαίδευσης, διατηρώντας τον ίδιο αριθμό στοιχείων στο δείγμα, δηλαδή κάθε δέντρο έχει την ίδια αναλογία σε δεδομένα, αν και διαφορετικά μεταξύ τους. Κάθε δέντρο, δίνει την δική του απάντηση (ταξινόμηση) και επιλέγεται ως τελική αυτήν που δίνουν τα περισσότερα δέντρα. Στον κώδικα μας, έχουν ανατεθεί

100 δέντρα (n_estimators) ώστε να βελτιωθεί η απόδοση και η σταθερότητα του μοντέλου, χωρίς να προκληθεί over-fitting στα δεδομένα.

### K-Nearest Neighbors

Ο αλγόριθμος K-Nearest Neighbors [11] είναι ένας αλγόριθμος που ταξινομεί τα δεδομένα με βάση τους K (όπου K το πλήθος) πλησιέστερους γείτονες που βρίσκονται κοντά τους. Δηλαδή, προβλέπει την ταξινόμηση μιας εταιρείας ανάλογα στο πόσο κοντά βρίσκεται σχετικά με τις υπόλοιπες. Αν βρίσκεται πολύ κοντά στις «Χρεωκοπημένες» θα καταταχθεί και αυτήν σε αυτή την κατηγορία. Τα δεδομένα, απλώνονται σε δισδιάστατο χώρο ώστε να γίνει η πρόβλεψη. Στον κώδικα μας, το πλήθος των γειτόνων (δηλ. το K n_neighbors) έχει οριστεί σε 5, καθώς είναι μια καλή τιμή που δεν ξεπερνά τα όρια απόφασης.

### Naïve Bayes

Ένας πολύ γνωστός αλγόριθμος [12], που βασίζεται στο θεώρημα του Bayes και κάνει την «αφελή» υπόθεση, ότι τα δεδομένα είναι ανεξάρτητα μεταξύ τους. Χρησιμοποιεί πιθανότητες, για να υπολογίσει σε ποια κατηγορία μπορεί να ανήκει ένα στοιχείο (μια εταιρεία), και επιλέγει την υψηλότερη πιθανότητα ώστε να κατατάξει το στοιχείο στην κατάλληλη κλάση. Στον κώδικα μας, δεν χρειάστηκε παραμετροποίηση, καθώς αποτελεί ένα γρήγορο πρότυπο σύγκρισης, χωρίς να χρειάζεται μεγάλο όγκο δεδομένων για να υπολογίσει.

### Support Vector Machines (SVM)

Τα SVM [13] είναι ένας ισχυρός αλγόριθμος που χρησιμοποιείται για να βρει το βέλτιστο υπερεπίπεδο, που διαχωρίζει τις κλάσεις, με το μέγιστο δυνατό περιθώριο. Για τους υπολογισμούς, εμπλέκεται η Επιχειρησιακή Έρευνα, αφού αφορά πρόβλημα μεγιστοποίησης. Προσπαθεί να βρει τα πλησιέστερα στοιχεία (support vectors) στο υπερεπίπεδο ώστε να κατατάξει ανάλογα τα στοιχεία στις κλάσεις. Το υπερεπίπεδο είναι ένα επίπεδο, που διαχωρίζει τις κλάσεις. Τα δεδομένα που δεν είναι γραμμικώς διαχωρίσιμα αναγνωρίζονται από συναρτήσεις πυρήνα (kernel) για να γίνει προβολή σε υψηλότερες διαστάσεις. Στον κώδικα μας, ορίστηκε η δυνατότητα υπολογισμού πιθανοτήτων για τον υπολογισμό της μετρικής ROC-AUC (probability=True).

### Gradient Boosting Classifier

Είναι μια τεχνική συνόλου [14, III], που χτίζει το μοντέλο, προσθετικά, χρησιμοποιώντας πολλαπλά δέντρα αποφάσεων σε ένα μόνο μοντέλο. Διορθώνει τα λάθη των προηγούμενων δέντρων, χρησιμοποιώντας έναν ρυθμό εκμάθησης που ελέγχει την συνεισφορά κάθε δέντρου. Κάθε δέντρο, εκπαιδεύεται πάνω στο σύνολο εκπαίδευσης, και προσπαθεί να διορθώσει τα σφάλματα, που προέκυψαν από τα προηγούμενα δέντρα. Η διαδικασία αυτή είναι επαναληπτική. Καταλήγει, σε ένα ισχυρό μοντέλο, βελτιώνοντας σταδιακά την ακρίβεια. Στον κώδικα μας, ορίζεται ότι θα κατασκευαστούν 100 ασθενή μοντέλα (δέντρα n_estimators), και ο ρυθμός εκμάθησης (learning_rate) ορίζεται σε 0.1, ώστε κάθε νέο δέντρο να χρησιμοποιεί αυτό το βήμα, για να διορθώσει τα σφάλματα. Αυτή η τιμή, απαιτεί περισσότερο χρόνο και περισσότερα δέντρα, αλλά εξασφαλίζει μεγαλύτερη ακρίβεια.

## Πειραματικά Αποτελέσματα

Σε αυτό το σημείο, θα γίνει παράθεση εικόνων και γραφημάτων, που προέκυψαν από την ανάλυση των δεδομένων στο μοντέλο. Κάθε εικόνα, συνοδεύεται από σχολιασμό, για καλύτερη κατανόηση.

Figure 1: Πλήθος υγιών vs Χρεοκοπημένων Εταιρειών ανά έτος

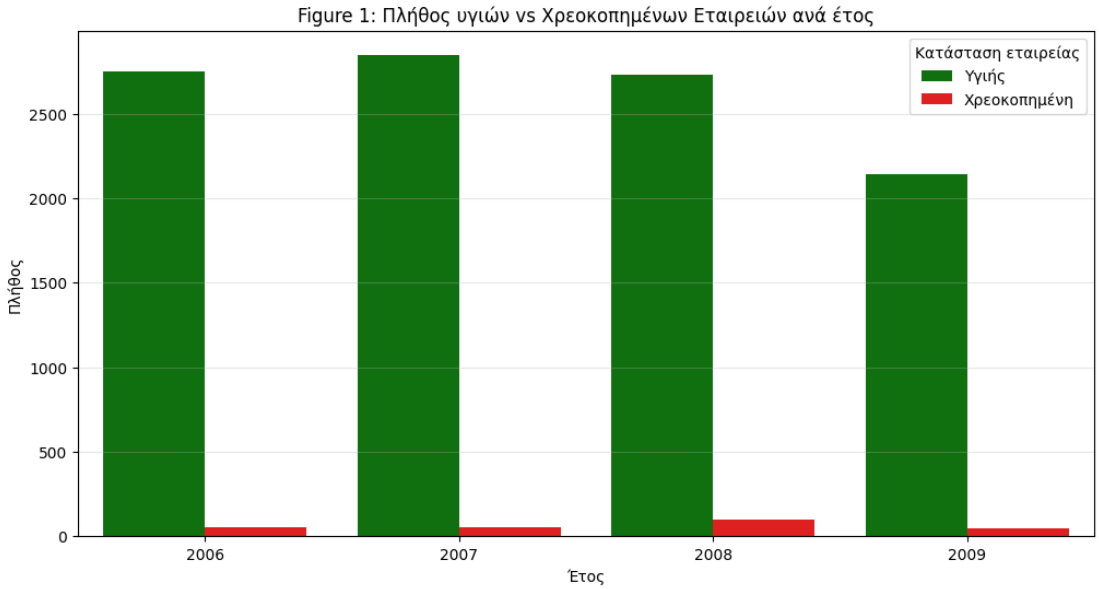

Σχολιασμός

Όπως αναφέρει και ο τίτλος, εδώ έχουμε ένα ραβδόγραμμα με πράσινες και κόκκινες μπάρες, όπου αντιπροσωπεύουν τις υγιείς και χρεωκοπημένες εταιρείες, αντίστοιχα. Ανά ημερολογιακό έτος, από το 2006 μέχρι και το 2009, οι υγιείς είναι συντριπτικά περισσότερες από τις χρεωκοπημένες. Το συμπέρασμα, που μπορούμε εύκολα να εξάγουμε, είναι πως τα δεδομένα έχουν εντονότατη ανισοκατανομή, και για αυτό στον κώδικα, χρησιμοποιείται η τεχνική εξισορρόπησης Stratified K-Fold.

Figure 2a: Στατιστικά (Min, Mean, Max) για Υγιείς Επιχειρήσεις

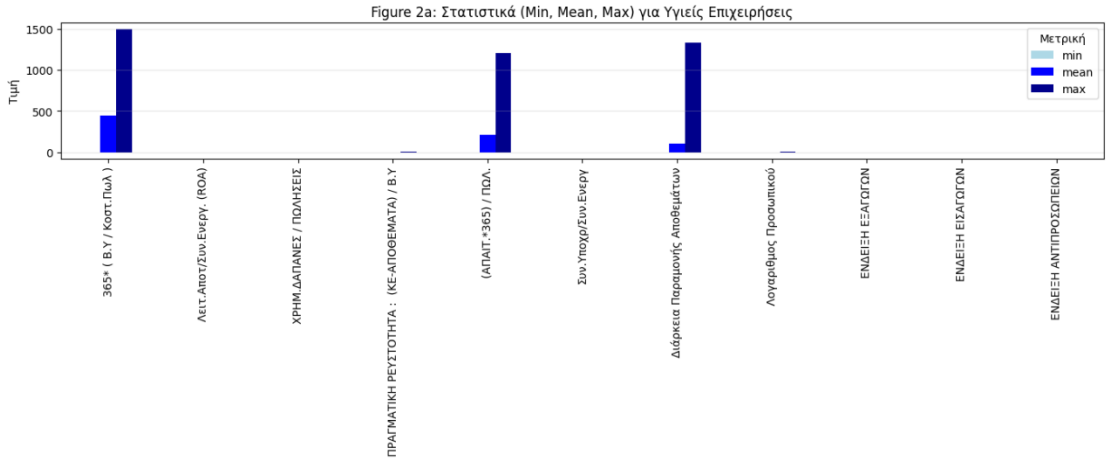


Σχολιασμός

Εδώ βλέπουμε, τεράστια ανομοιογένεια στα χαρακτηριστικά εισόδου, που αφορούν τις υγιείς επιχειρήσεις. Συγκεκριμένα, 3 χαρακτηριστικά/δείκτες, έχουν τιμές που ξεπερνούν το 1000, ενώ όλα τα υπόλοιπα, οριακά δεν φαίνονται στο γράφημα. Είναι διακριτό, ωστόσο, πόσο μεγάλη είναι η απόκλιση της μέσης τιμής (mean) από την μέγιστη τιμή (max), αλλά και από την ελάχιστη τιμή (min) στους 3 αυτούς δείκτες. Αυτό το γεγονός, σηματοδοτεί ύπαρξη ακραίων τιμών (outliers), και επισημαίνει την σημασία της κανονικοποίησης. Χωρίς την κανονικοποίηση, τα δεδομένα θα εισαγόταν με μεγάλες αποκλίσεις και το μοντέλο θα εξήγαγε βεβιασμένα αποτελέσματα.

## Figure 2b: Στατιστικά (Min, Mean, Max) για Χρεωκοπημένες Επιχειρήσεις

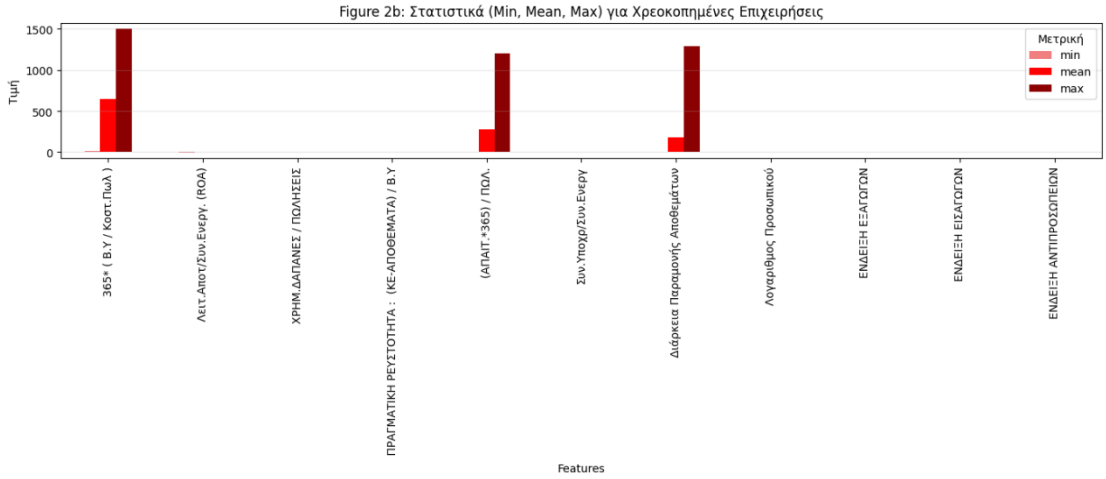


## Σχολιασμός

Και σε αυτό το γράφημα, μπορούμε να παρατηρήσουμε, ότι είδαμε και στο προηγούμενο γράφημα. Ανομοιογένεια στους χρηματοοικονομικούς δείκτες. Βλέπουμε πάλι, μεγάλες αποκλίσεις μεταξύ ελάχιστων, μέσων και μέγιστων τιμών και γίνεται όλο και πιο επιτακτική η ανάγκη για κανονικοποίηση των τιμών στο διάστημα [0,1], όπως και έγινε στον κώδικα.

## Pivot Table από την ανάλυση που έγινε στο Excel

| Row Labels | Average of Recall | Average of F1 Score | Average of True Negative Rate (TNR - Specificity) |
|---|---|---|---|
| Test | 0,452620968 | 0,176658025 | 0,909139759 |
| Decision Tree | 0,467741935 | 0,138440945 | 0,866068017 |
| Gradient Boosting | 0,524193548 | 0,20125076 | 0,911253344 |
| KNN | 0,471774194 | 0,155968291 | 0,892911731 |
| LDA | 0,403225806 | 0,182707929 | 0,929403898 |
| Logistic Regression | 0,358870968 | 0,180333702 | 0,938192587 |
| Naive Bayes | 0,516129032 | 0,150091232 | 0,873614826 |
| Random Forest | 0,504032258 | 0,209695601 | 0,921379442 |
| SVM | 0,375 | 0,194775739 | 0,94029423 |
| Grand Total | 0,452620968 | 0,176658025 | 0,909139759 |

## Σχολιασμός

Ο Pivot Table συνοψίζει τη μέση επίδοση (Average) των οκτώ αλγορίθμων στο Test set, μετά την εφαρμογή της διαδικασίας Stratified K-Fold. Λαμβάνονται υπ' όψιν 3 μετρικές, που απαιτούνται για τελική αξιολόγηση, και είναι χρήσιμες για να μπορέσουμε να απαντήσουμε εάν πληρούνται οι προϋποθέσεις. Συγκεκριμένα, όσον αφορά τους δύο περιορισμούς στην απόδοση, το μοντέλο δεν μπορεί να πιάσει το ελάχιστο όριο επιτυχίας 60%

για να βρει τις εταιρείες που θα πτωχεύσουν. Αυτό, φαίνεται από τον μέσο όρο της μετρικής Recall, η οποία μετράει το ποσοστό των εταιρειών που τελικά χρεωκοπούν. Ωστόσο, το μοντέλο μπορεί με μεγάλη επιτυχία να βρίσκει τις εταιρείες που δεν θα πτωχεύσουν, και με επιτυχία άνω του ελάχιστου ορίου 70%. Η μετρική TNR, μετράει ακριβώς αυτό το ποσοστό, δηλαδή τις εταιρείες που το μοντέλο υπολόγισε σωστά πως δεν θα χρεωκοπήσουν και δεν χρεωκόπησαν.

Συγκριτικός πίνακας επιδόσεων στο Test Set, με βάση το F1 Score

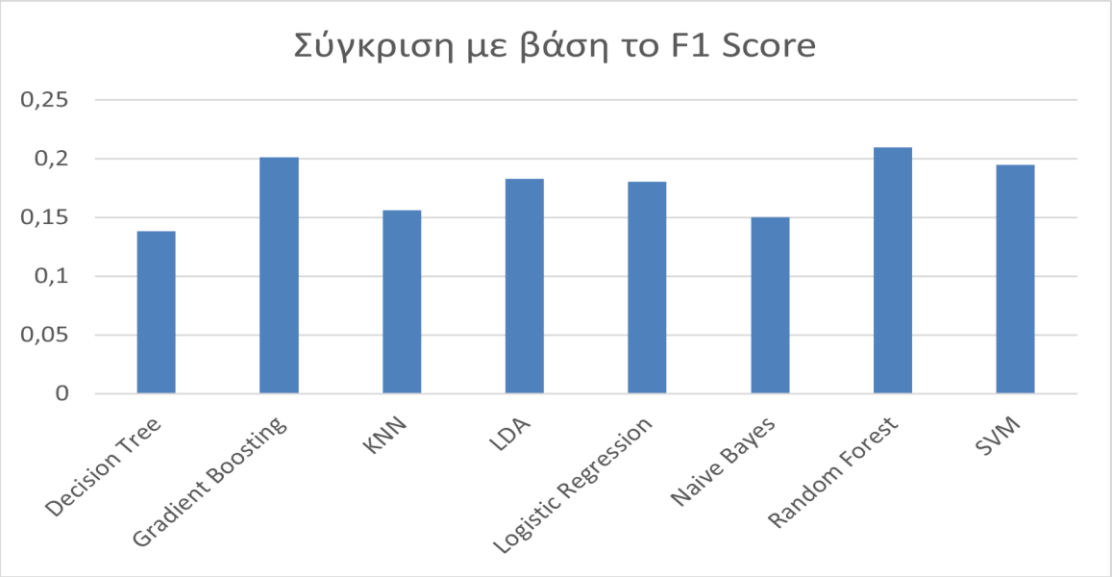


Σχολιασμός

Το συγκεκριμένο γράφημα, αποτελεί γράφημα του Excel με δεδομένα που υπήρχαν σε Pivot Table. Τα δεδομένα αυτά, προέχονται από τα τελικά αποτελέσματα του μοντέλου και δείχνουν πόσο καλά τα πήγαν τα 8 μοντέλα, στην εξέταση του Test Set, με βάση την μετρική F1. Η μετρική F1 είναι ο αρμονικός μέσος όρος των Precision, Recall. Το υψηλότερο ποσοστό κατέχει το μοντέλο των Random Forests και ακολουθεί το Gradient Boosting. Αυτό αποδεικνύει ότι, μέθοδοι που περιλαμβάνουν Decision Trees και γενικότερα μέθοδοι που περιλαμβάνουν σύνολα ανταπεξέρχονται καλύτερα στην πολυπλοκότητα και στον όγκο των δεδομένων. Μπορεί τα νούμερα να είναι γενικά μικρά, αλλά αυτό είναι αναμενόμενο, διότι το DataSet είναι ανισομερές, αφού οι περισσότερες εταιρείες είναι υγιείς και εμείς προσπαθούμε να βρούμε αυτές που θα χρεωκοπήσουν.

Συγκριτικός πίνακας επιδόσεων με βάση το Recall και το TNR

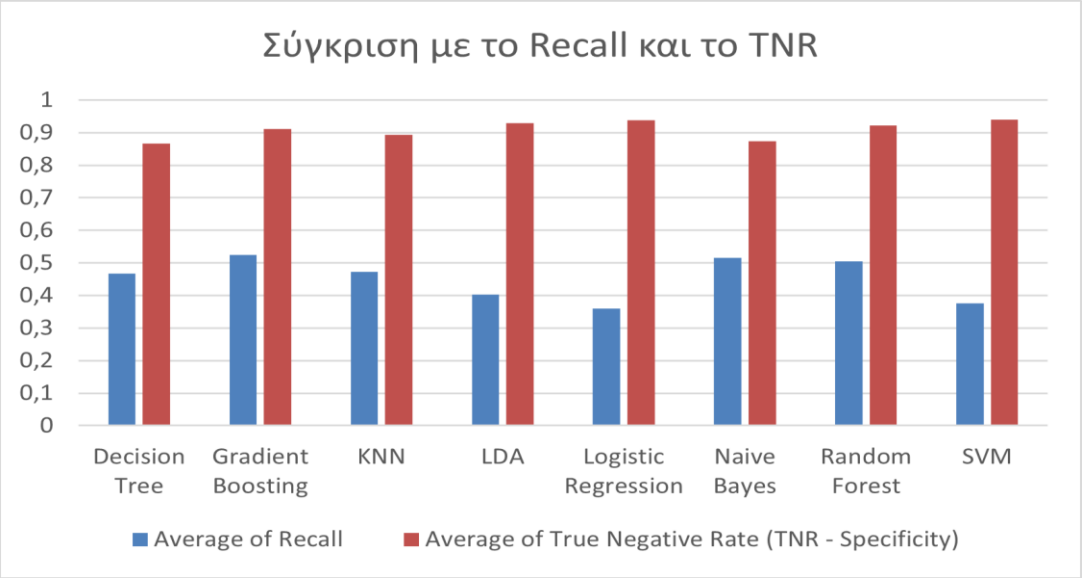


Σχολιασμός

Το γράφημα αυτό, είναι εξαιρετικά σημαντικό για να απαντήσουμε στα βασικά ερωτήματα του προβλήματος, δηλαδή στα ποσοστά επιτυχίας που πρέπει να προσεγγίσουν τα μοντέλα που αναπτύχθηκαν, ώστε να θεωρηθούν αξιόπιστα. Σχετικά με τον πρώτο περιορισμό, για το ποσοστό άνω του 60% για τις εταιρείες που θα πτωχεύσουν, μπορούμε να απαντήσουμε ρητά πως δεν καλύπτεται από τα δεδομένα που μας δόθηκαν. Η μπλε μπάρα που αφορά την μετρική Recall, δεν προσεγγίζει το 0,6 που θα θέλαμε. Το μοντέλο όμως, που βρίσκεται αρκετά κοντά, είναι το Gradient Boosting με ποσοστό παραπάνω από 0,5. Ακολουθούν το Naïve Bayes και το Random Forest. Μπορεί να δοθεί ως εξήγηση, το γεγονός ότι τα μοντέλα θυσιάζουν τις χρεωκοπίες, για να μην χαλάσουν την απόδοση τους στον εντοπισμό των υγιών εταιρειών. Αυτό οφείλεται, στο ότι η χρεωκοπία είναι σχετικά σπάνιο γεγονός και ακόμα και με undersampling (3:1) τα δεδομένα παραμένουν υπέρ των υγιών εταιρειών. Η στρατηγική της αναλογίας υποδειγματοληψίας, επηρεάζει τελικά τα αποτελέσματα του μοντέλου, προς την αντίθετη πλευρά, στην συγκεκριμένη περίπτωση.

Σχετικά με τον δεύτερο περιορισμό, φαίνεται και στο ραβδόγραμμα, ότι έχουμε εξαιρετική επιτυχία και όχι μόνο πιάνουμε το ποσοστό 70%, αλλά κάθε μοντέλο έχει κατ' ελάχιστον 80% επιτυχία. Είναι αναμενόμενο, διότι τα δεδομένα υπερτερούν για τις υγιείς εταιρείες. Βλέπουμε ότι το Logistic Regression και το SVM, έχουν τα υψηλότερα ποσοστά, και αποδεικνύουν

ότι είναι εξαιρετικά αξιόπιστα μοντέλα για τον εντοπισμό υγιών επιχειρήσεων και στο να μην τις χαρακτηρίζουν ως Χρεωκοπημένες. Τα άλλα μοντέλα είναι εξίσου καλά και έχουν σχεδόν ίδιες αποδόσεις με τα γραμμικά. Η υπεροχή των γραμμικών μοντέλων στην Ειδικότητα (Specificity) οφείλεται στο γεγονός ότι, οι υγιείς εταιρείες συγκεντρώνονται σε μια περιοχή του διανυσματικού χώρου και τα γραμμικά μοντέλα, μπορούν πολύ εύκολα να τις διαχωρίσουν και να χαράξουν την ευθεία γραμμή στο επίπεδο. Ακόμα και αν μερικές υγιείς εταιρείες βρισκόταν διάσπαρτες στον διανυσματικό χώρο, τα γραμμικά μοντέλα δεν θα άλλαζαν τα όρια τους, ούτε θα έκαναν άλλη χάραξη της γραμμής. Βέβαια, όλα αυτά λειτουργούν, λόγω υπεροχής των υγιών εταιρειών στο DataSet. Ενδεχομένως, αν είχαμε διαφορετικά δεδομένα και υπήρχαν άλλες αναλογίες, αυτήν η μετρική να είχε άλλο αποτέλεσμα.

### Confusion Matrix για τον αλγόριθμο Gradient Boosting

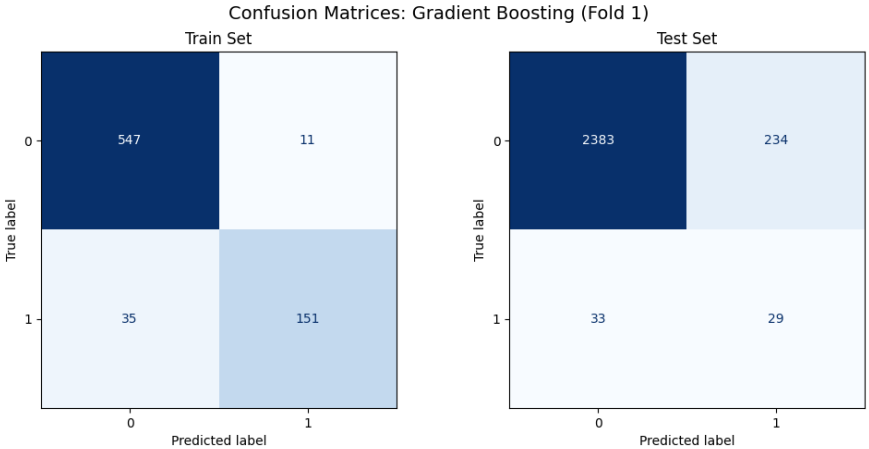


<u>Σχολιασμός</u>

Στην εικόνα απεικονίζονται οι Πίνακες Σύγχυσης (Confusion Matrices) για το μοντέλο Gradient Boosting (Fold 1), τόσο για το σύνολο εκπαίδευσης (Train Set - αριστερά) όσο και για το σύνολο ελέγχου (Test Set - δεξιά).

Στο αριστερό διάγραμμα, παρατηρούμε τα αποτελέσματα στο υποδειγματισμένο (undersampled) σύνολο, όπου διατηρήθηκε η αναλογία 3:1. Το μοντέλο έχει εκπαιδευτεί επιτυχώς, καθώς επιτυγχάνει υψηλή ακρίβεια και στις δύο κλάσεις. Συγκεκριμένα, αναγνώρισε σωστά 151 χρεωκοπημένες εταιρείες (True Positives), χάνοντας μόνο 35 (False Negatives), γεγονός που δείχνει ότι έμαθε καλά τα μοτίβα της χρεωκοπίας κατά τη φάση της εκπαίδευσης.

Στο δεξί διάγραμμα, βλέπουμε την επίδοση στην πραγματική, ανισομερή κατανομή των δεδομένων (Imbalanced Data).

True Negatives (Πάνω Αριστερά - 2383): Το μοντέλο αναγνώρισε σωστά τη συντριπτική πλειοψηφία των υγιών εταιρειών. Αυτό επιβεβαιώνει την υψηλή Ειδικότητα (Specificity - TNR > 90%) που είδαμε στα γραφήματα, δείχνοντας ότι το μοντέλο είναι αξιόπιστο και δεν απορρίπτει εύκολα υγιείς επιχειρήσεις.

True Positives (Κάτω Δεξιά - 29): Το μοντέλο κατάφερε να εντοπίσει 29 χρεωκοπημένες εταιρείες.

False Negatives (Κάτω Αριστερά - 33): Υπάρχουν 33 εταιρείες που χρεωκόπησαν αλλά το μοντέλο τις θεώρησε υγιείς. Το γεγονός ότι τα TP (29) και τα FN (33) είναι συγκρίσιμα μεγέθη, εξηγεί γιατί το Recall κυμαίνεται κοντά στο 50%.

False Positives (Πάνω Δεξιά - 234): Παρατηρούμε 234 «λάθος συναγερμούς». Για να βρούμε τις 29 χρεωκοπημένες, χρειάστηκε να χαρακτηρίσουμε ως ύποπτες και κάποιες υγιείς.

## Συμπεράσματα

Σε αυτό το πρόβλημα, κληθήκαμε να παρουσιάσουμε μια αναφορά για τον εντοπισμό εταιρειών, που πρόκειται να χρεωκοπήσουν με βάση οικονομικούς δείκτες που δόθηκαν για ανάλυση σε μοντέλα Μηχανικής Μάθησης. Από αυτά τα μοντέλα, συλλέξαμε πολύ σημαντικές πληροφορίες σχετικά με την κατανομή των δεδομένων, και μπορούμε πλέον να προβούμε σε τελικά συμπεράσματα για να τα χαρακτηρίσουμε.

Καλύτερο μοντέλο, θα χαρακτηρίσουμε το μοντέλο Gradient Boosting. Γενικά, φάνηκε μέσα στην εργασία, πως τα μοντέλα που περιέχουν Decision Trees, απέδωσαν καλύτερα σε σχέση με τα υπόλοιπα. Ωστόσο, το Gradient Boosting, θεωρούμε ότι προσέγγισε (χωρίς να τον αγγίξει) τον βασικό στόχο, δηλαδή να βρει τις εταιρείες που θα πτωχεύσουν. Η τεχνική της διόρθωσης λαθών, φαίνεται να αποδίδει και να επηρεάζει σε μεγάλο βαθμό τον εντοπισμό πιο σύνθετων και μη γραμμικών μοτίβων χρεωκοπίας. Άλλωστε, το μοντέλο αυτό, έπιασε και το υψηλότερο ποσοστό Recall, όπως φαίνεται στο Pivot Table. Εξίσου καλά, τα κατάφερε και στον δεύτερο περιορισμό για τον εντοπισμό εταιρειών που δεν θα πτωχεύσουν.

Οι περιορισμοί δεν είναι τηρούνται απόλυτα, αλλά έχουμε καταφέρει μια αρκετά καλή προσέγγιση με το μοντέλο Gradient Boosting. Ο πρώτος στόχος είναι αυτός που δεν ικανοποιήθηκε πλήρως, ωστόσο ο δεύτερος καλύπτεται άνετα. Η αδυναμία επίτευξης του πρώτου, δεν σημαίνει αποτυχία. Επιλέξαμε μια αναλογία 3 προς 1, για να διατηρήσουμε την αξιοπιστία στις υγιείς εταιρείες. Μια άλλη αναλογία, μπορεί να έδινε διαφορετική αξιοπιστία και ίσως να έπιανε τον πρώτο στόχο. Θα μπορούσε όμως, να ρίξει τον δεύτερο στόχο και να απέρριπτε λανθασμένα πολλές υγιείς εταιρείες.

Σε κάθε περίπτωση, κάθε απόφαση εξαρτάται από τα δεδομένα που μας παρέχονται και τις στρατηγικές που επιλέγει κάθε οργανισμός να ακολουθήσει.

## Αναφορές σε ιστοτόπους

1. https://pandas.pydata.org/docs/user_guide/dsintro.html#dataframe
2. https://pandas.pydata.org/docs/getting_started/index.html
3. https://matplotlib.org/stable/users/index.html
4. https://www.w3schools.com/python/matplotlib_intro.asp
5. https://scikit-learn.org/stable/modules/cross_validation.html#stratified-k-fold
6. https://machinelearningmastery.com/k-fold-cross-validation/
7. https://en.wikipedia.org/wiki/Linear_discriminant_analysis
8. https://www.geeksforgeeks.org/machine-learning/understanding-logistic-regression/
9. https://scikit-learn.org/stable/modules/tree.html
10. https://www.geeksforgeeks.org/machine-learning/random-forest-algorithm-in-machine-learning/
11. https://www.geeksforgeeks.org/machine-learning/k-nearest-neighbours/
12. https://www.geeksforgeeks.org/machine-learning/naive-bayes-classifiers/
13. https://www.geeksforgeeks.org/machine-learning/support-vector-machine-algorithm/
14. https://www.geeksforgeeks.org/machine-learning/ml-gradient-boosting/

## Βιβλιογραφικές αναφορές

I. Pedregosa, F., et al. (2011). "Scikit-learn: Machine Learning in Python". Journal of Machine Learning Research, 12, 2825-2830.
II. Brownlee, J. (2020). A Gentle Introduction to Imbalanced Classification. Machine Learning Mastery.
III. Friedman, J. H. (2001). "Greedy function approximation: A gradient boosting machine". Annals of Statistics, 1189-1232.