Μηχανική Μάθηση

3η Εργασία – Regression problems

Το πρόβλημα που θα αντιμετωπίσετε αφορά στην **πρόβλεψη της εξέλιξης μιας ιατρικής κατάστασης** (διαβήτης) με βάση δημογραφικά και βιοχημικά χαρακτηριστικά ασθενών.

Σκοπός της εργασίας είναι να παραδώσετε μια αναφορά που παραθέτει αναλυτικά και συγκριτικά αποτελέσματα σχετικά με την ικανότητα διαφορετικών τεχνικών παλινδρόμησης να ανταπεξέλθουν στο συγκεκριμένο πρόβλημα.

Προσοχή: θεωρήστε ότι το συγκεκριμένο πρόβλημα σας έχει δοθεί στο πλαίσιο αξιολόγησης για μια θέση στην οποία είστε υποψήφιος/α. Η αναφορά πρέπει να είναι προσεκτικά δομημένη και τα αποτελέσματα να είναι **ερμηνεύσιμα και κατανοητά**.

Τα δεδομένα προέρχονται από το ενσωματωμένο **Diabetes dataset** της scikit-learn. Κάθε γραμμή αντιστοιχεί σε έναν ασθενή και περιλαμβάνει:

- 10 περιγραφικά χαρακτηριστικά (ηλικία, BMI, αρτηριακή πίεση, δείκτες αίματος, κ.λπ.).
- Μία συνεχόμενη μεταβλητή εξόδου (μέση τιμή ζαχάρου στο αίμα [mg/dL]), που δείχνει την **κατάσταση του ασθενή** μετά από ένα έτος.

Για την συγκεκριμένη άσκηση θα παραδώσετε ένα αρχείο σε python στο οποίο θα παρουσιάζετε τις διαφορές στα αποτελέσματα των μοντέλων παλινδρόμησης καθώς και την ερμηνεία των αποτελεσμάτων (explainability) με χρήση της βιβλιοθήκης SHAP.

Συνολικά πρέπει να χρησιμοποιήσετε τέσσερις (4) διαφορετικές τεχνικές regression. Οι δύο (2) εκ των οποίων *πρέπει* να είναι:

1. Random Forrest.
2. Gaussian Process Regression.

Οι υπόλοιπες δύο τεχνικές επαφίονται στην επιλογή σας.

Η αξιολόγηση της καταλληλότητας των cluster θα γίνει με χρήση τεσσάρων (4) μετρικών απόδοσης. Οι τρείς (3) εξ' αυτών είναι οι:

1. Root mean squared error
2. Mean absolute error
3. Max error

Η 4η μετρική είναι της επιλογής σας (όχι όμως το MSE).

Ο κώδικας που θα παραδώσετε, σε γλώσσα Python, πρέπει να υλοποιεί τα ακόλουθα:

1. Θα φορτώνει το diabetes datast με χρήση της ακόλουθης εντολής:

   diabetes_data = load_diabetes(as_frame=True, scaled=False)

2. Θα τυπώνει το εύρος τιμών για μία από τις στήλες του dataframe.
3. Θα ελέγχει για NaN τιμές [και θα απομακρύνει τις αντίστοιχες εγγραφές].
4. Θα τυπώνει (plot) ένα γράφημα συχνοτήτων (histogram) για την στήλη 'target'.
5. Θα κανονικοποιεί τα δεδομένα (εισόδου και εξόδου) με χρήση του Min-Max scaling.
6. Θα ορίζει ένα σταθερό αριθμό για seed. Είναι μια καλή πρακτική που εξασφαλίζει την επανάληψη του πειράματος υπό τις ίδιες συνθήκες.
7. Θα χωρίσεις τα δεδομένα σε 6 folds, με χρήση ου KFold (sklearn.model_selection). Προσοχή στα ακόλουθα:
   a. Το kfold θα χρησιμοποιεί το seed ως όρισμα.
   b. Το setup θα δίνει δείκτες που περιγράφουν ποιες γραμμές πάνε στο κάθε fold. ΜΗΝ κάνετε replicate τα δεδομένα
8. Θα δημιουργήσετε μια λίστα με όνομα csv_data, στην οποία καταχωρούνται τα αποτελέσματα κατά την εκτέλεση του κώδικα. Το αρχικό statement θα είναι:

```
# Create a list to store the data
csv_data = []
# Append header row
csv_data.append(["Model", "Set", "Fold",\
        "Max_n", "RMSE_n", "MAE_n", "MAPE_n",\
        "Max", "RMSE", "MAE", "MAPE"])
```

9. Θα ξεκινήσετε να εκτελείτε ένα for loop με βάση το kfold setup που έχετε υλοποιήσει. Για κάθε fold η διαδικασία θα είναι η ίδια:
   a. Εκπαίδευση του μοντέλου πάνω στα train data (για το συγκεκριμένο fold, όχι ολόκληρου του set)
   b. Κατά την εκπαίδευση θα χρησιμοποιήσετε την ρουτίνα RandomizedSearchCV, για να υπολογίσετε τις καλύτερες υπερπαραμέτρους του μοντέλου
   c. Με το που ολοκληρωθεί η εκπαίδευση θα κάνετε predict τις τιμές τόσο στο train, όσο και στο test set.
   d. Αφού γίνει η πρόβλεψη, θα επαναφέρετε τα προβλεπόμενα νούμερα στο πραγματικό εύρος τιμών (denormalize).
   e. Θα υπολογίσετε τα error metrics.
   f. Θα δημιουργήσετε μια γραφική παράσταση τύπου actual vs predicted values.
   g. Θα κάνετε append τα αποτελέσματα στο csv data.
   h. Θα τρέξετε ένα SHAP explainer και θα αποθηκεύσετε δύο (2) plots: το SHAP summary plot και ένα waterfall plot (για 2 παραδείγματα της επιλογής σας, για κάθε fold).

Χρησιμοποιώντας τα αποτελέσματα, τις γραφικές παραστάσεις και εικόνες του κώδικα, καθώς και γραφικές παραστάσεις που θα φτιάξετε στο excel, θα συντάξετε μια έκθεση στην οποία θα παρουσιάζετε τα συμπεράσματα σας, θα κάνετε συγκριτικές αξιολογήσεις και θα προτείνετε ποιος

Ακολουθούν μερικά *ενδεικτικά* παραδείγματα σχετικά με τα plots που πρέπει να παράγετε (και μετά να αναλύσετε).

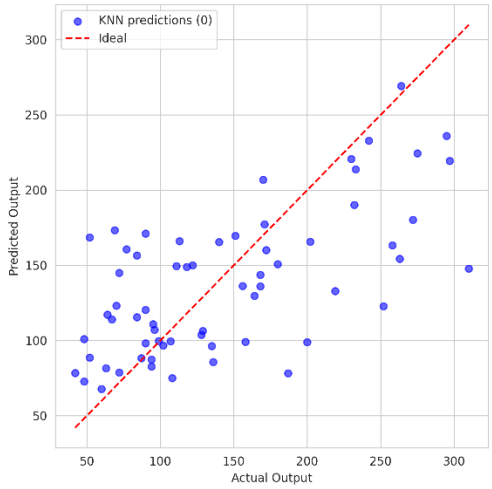

Εικόνα 1 Actual vs predicted values, KNN regressor, test set, fold 0

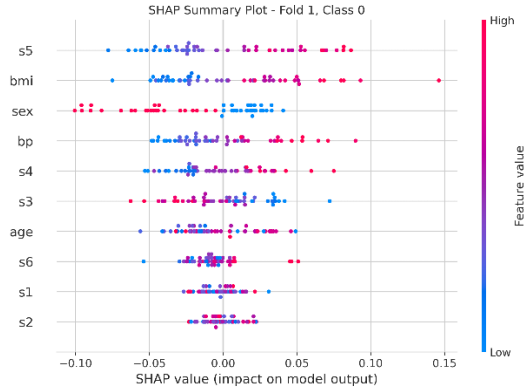

Εικόνα 2 SHAP summary plot, for KNN regressor, test set

Ακολουθεί παράδειγμα (μερικές γραμμές) του csv που θα δημιουργήσει ο κώδικας (και θα το χρησιμοποιήσετε μετά για να φτιάξετε τις κατάλληλες γραφικές παραστάσεις).

Πίνακας 1 Παράδειγμα πειραματικών αποτελεσμάτων, σε κανονικοποιημένες και αρχικής κλίμακας τιμές εξόδου.

Model	Set	Fold	Max_n	RMSE_n	MAE_n	ERROR_n	Max	RMSE	MAE	ERROR
SVR	Train	1	0.481	0.1666	0.1342	10442063	154.4117	53.4761	43.0701	38.8962
SVR	Test	1	0.5106	0.1757	0.1378	58.6791	163.8978	56.4032	44.2312	38.583
DT	Train	1	0.6402	0.1789	0.134	5892686	205.5	57.4366	43.0053	36.6252
DT	Test	1	0.6386	0.2135	0.1655	70.5465	205	68.5349	53.1328	46.771

Σημαντική παρατήρηση: Αξιολογείστε με βάση την αναφορά που θα παραδώσετε, εργασία που *δεν* συνοδεύεται από γραπτή αναφορά βαθμολογείται με 0.

Οδηγίες:

Α. Οι εργασίες είναι σε ομάδες μέχρι τέσσερα (4) άτομα. Κάθε άτομο μπορεί να υποβάλει εργασία σε μία μόνο ομάδα κάθε φορά.

Β. Οι εργασίες θα πρέπει να αναρτώνται στο eClass σε ένα αρχείο zip (όχι rar) εντός της προβλεπόμενης προθεσμίας. Δεν θα δοθεί παράταση. **Προσοχή**: Κάθε ομαδική εργασία θα υποβάλλεται μόνο από ένα μέλος της ομάδας (εσείς επιλέγετε ποιος/ποια).

Γ. Κάθε εργασία πρέπει να συνοδεύεται από:

- Τα **αρχεία .py** που περιέχουν τις απαντήσεις στα ερωτήματα
- Μια **αναφορά** σε pdf **(και μόνο σε pdf)**, που θα ακολουθεί όλες τις καλές πρακτικές, όπως αυτές περιγράφονται στο έντυπο: «Καλές πρακτικές checklist.pdf»

Να θυμάστε ότι:

- Ο κώδικας *πρέπει* να συνοδεύεται από κατάλληλα σχόλια, στα αγγλικά.
- Αν κάτι δεν διευκρινίζεται, έχετε το δικαίωμα να κάνετε όποια υλοποίηση σας βολεύει.
- Οι βιβλιοθήκες που θα χρησιμοποιήσετε *πρέπει* να μπορούν να εγκατασταθούν μέσω του pip.
- Ο κώδικας *πρέπει* να τρέχει σε Google Colab.
- Η υποβολή γίνεται αποκλειστικά μέσω του eclass.
- Δεν θα δοθεί παράταση στην προθεσμία υποβολής.

Καταληκτική Ημερομηνία Παράδοσης: **Βλέπε μενού Εργασίες, στο eclass**.