ΠΑΝΕΠΙΣΤΗΜΙΟ ΜΑΚΕΔΟΝΙΑΣ
ΤΜΗΜΑ ΕΦΑΡΜΟΣΜΕΝΗΣ ΠΛΗΡΟΦΟΡΙΚΗΣ

Αναφορά – PP2

SENTIMENT ANALYSIS ΣΕ ΚΡΙΤΙΚΕΣ ΤΑΙΝΙΩΝ

ΑΠΟΣΤΟΛΟΣ ΣΙΝΙΟΡΗΣ (ics24123)
ΜΑΘΗΜΑ: ΜΗΧΑΝΕΣ ΑΝΑΖΗΤΗΣΗΣ ΚΑΙ ΑΝΑΛΥΣΗ ΚΕΙΜΕΝΟΥ
ΕΠΙΒΛΕΠΟΥΣΑ ΚΑΘΗΓΗΤΡΙΑ: ΓΕΩΡΓΙΑ ΚΟΛΩΝΙΑΡΗ

Πίνακας περιεχομένων

Εισαγωγή 2
Περιγραφή των δεδομένων (DataSet) 3
Προεπεξεργασία δεδομένων 4
Lower Casing 4
Tokenization 4
Stopwords removal & Stemming 4
Word2Vec 4
Εκπαίδευση μοντέλων και Cross Validation 5
K-Fold Cross Validation 5
Pipelines και Εκπαίδευση 5
1. Multinomial NB & Binary 5
2. Multinomial NB & TF-IDF 5
3. Bernoulli NB & Binary 6
4. Boolean(Binarized) Multinomial NB & Binary 6
5. Multinomial NB & Word2Vec 6
Πειραματικά Αποτελέσματα του Μέρους Α 7
Γλωσσική προεπεξεργασία και Baseline 8
Διαχείριση Άρνησης (Negation) 8
POS (Part-Of-Speech tag) 8
Στάθμιση Θέσης (Position Weighting) 8
Πειραματικά Αποτελέσματα του Μέρους Β 9
Σύγκριση με το RapidMiner 10
Συμπεράσματα 12
Αναφορές σε ιστοτόπους - Βιβλιογραφία 13

Εισαγωγή

Στην παρούσα εργασία, κληθήκαμε να λύσουμε ένα πρόβλημα Ανάλυσης Συναισθήματος (Sentiment Analysis). Η Ανάλυση Συναισθήματος ή Εξόρυξη Γνώμης (Opinion Mining) είναι μία τεχνική της Επεξεργασίας Φυσικής Γλώσσας (Natural Language Processing - NLP) η οποία μέσω Μηχανικής Μάθησης (Machine Learning), προσπαθεί να αναγνωρίσει μέσα σε πολλά κείμενα λέξεις που υποδηλώνουν γνώμες, συναισθήματα και γενικότερα λέξεις που να δηλώνουν οποιαδήποτε ψυχολογική κατάσταση. [1] Σκοπός είναι, να μπορέσουμε με εξάγουμε αντικειμενικά συμπεράσματα με βάση την ταξινόμηση των λέξεων και των φράσεων σε κατηγορίες, όπως «θετικό - positive», «αρνητικό - negative» και «ουδέτερο - neutral». Είναι σαφές, ότι πρόκειται για ένα ευρύτερο πρόβλημα Ταξινόμησης (Classification) στον τομέα της Μηχανικής Μάθησης.

Το πρόβλημα μας, αφορά κριτικές ταινιών από τις οποίες θα προσπαθήσουμε να εξάγουμε συμπεράσματα για την κατηγοριοποίηση τους σε «Θετικές» και «Αρνητικές». Για τον λόγο αυτό, χρησιμοποιήθηκαν διάφορες τεχνικές επεξεργασίας του φυσικού κειμένου αλλά και κατηγοριοποιητές, οι οποίοι βασίζονται στον γνωστό αλγόριθμο Naïve Bayes. Μπορούμε, από αυτό να καταλάβουμε, πως οι Πιθανότητες έχουν καίρια σημασία στην επίλυση τέτοιου είδους προβλημάτων, καθώς χωρίς αυτές δεν θα μπορούσαν να γίνουν οι απαραίτητοι μαθηματικοί υπολογισμοί για την κατηγοριοποίηση του κειμένου.

Ακολουθούν στις παρακάτω ενότητες, η περιγραφή των δεδομένων (DataSet), οι περιγραφές των τεχνικών προεπεξεργασίας του κειμένου για την είσοδο στο μοντέλο Μηχανικής Μάθησης αλλά και συγκρίσεις με το πρόγραμμα Ανάλυσης Δεδομένων, RapidMiner. Οι συγκρίσεις αυτές, βασίζονται σε μετρικές αξιολόγησης και θα αναλυθούν στην υπόλοιπη έκταση της αναφοράς.

Περιγραφή των δεδομένων (DataSet)

Το DataSet, προέρχεται από το τμήμα Επιστήμης Υπολογιστών του Πανεπιστημίου Cornell, για ερευνητικά πειράματα, όπως η συγκεκριμένη εργασία. Η πρόσβαση στην σελίδα πληροφοριών γίνεται από εδώ, ενώ η αποθήκευση των δεδομένων γίνεται εδώ.

Συνολικά, υπάρχουν 2000 κριτικές ταινιών, εκ των οποίων οι 1000 κατατάσσονται στην κατηγορία 1 (Θετικό) και οι υπόλοιπες 1000 στην κατηγορία 0 (Αρνητικό). Τα δεδομένα είναι ήδη σε μορφή tokenized κειμένου (δηλαδή, χωρισμένα σε λέξεις), ωστόσο απαιτήθηκε περαιτέρω επεξεργασία των δεδομένων για να μπορέσουν ύστερα, να εισαχθούν στους αλγορίθμους Μηχανικής Μάθησης. Επιπλέον, τα δεδομένα είναι ήδη σε κατηγορίες (0 ή 1), καθώς οι δημιουργοί του DataSet, είχαν ταξινομήσει τα δεδομένα με βάση τα «αστέρια» που είχαν ως κριτική οι αναφερόμενες ταινίες στην πλατφόρμα IMDB.

Ενδεικτικά, παρέχεται ένα στιγμιότυπο από την αρχική μορφή των δεδομένων, πριν γίνει προεπεξεργασία τους στο μοντέλο μας.

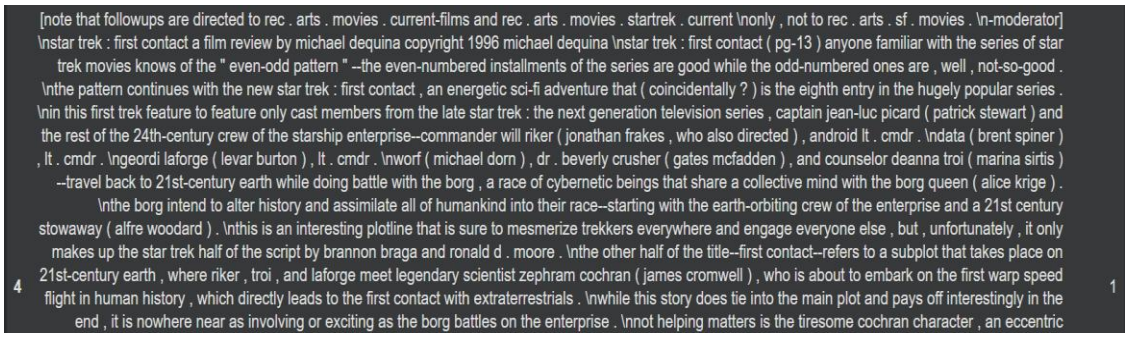

Στην εικόνα φαίνεται, από αριστερά το κείμενο της κριτικής και από δεξιά η κατηγορία 0 ή 1, ανάλογα με την κατάταξη που έδωσαν οι δημιουργοί.

Προεπεξεργασία δεδομένων

Τα δεδομένα δέχθηκαν διάφορες μορφές επεξεργασίας πριν δοθούν στο μοντέλο, καθώς αυτό είναι απαραίτητο για την σωστή λειτουργία των ταξινομητών (classifiers).

Lower Casing

Αρχικά, αφαιρέθηκαν όλοι οι μη αλφαβητικοί χαρακτήρες (όπως HTML ετικέτες και σημεία στίξης) και στην συνέχεια, προχωρήσαμε σε μετατροπή σε πεζά γράμματα, ώστε οι αλγόριθμοι να μην θεωρούν ως διαφορετική μία λέξη, που απλώς ξεκινάει με κεφαλαίο γράμμα.

Tokenization

Στην συνέχεια, οι λέξεις μετατράπηκαν σε tokens, ώστε να μπορέσουν να εισαχθούν με την απαραίτητη μορφή στο DataFrame και ύστερα στους αλγορίθμους.

Stopwords removal & Stemming

Τα stopwords αφαιρέθηκαν, καθώς σε μερικές αναπαραστάσεις των εγγράφων (π.χ. Πλήθος εμφανίσεων) θα αλλοίωναν το τελικό αποτέλεσμα. Τελευταίο στάδιο, αποτέλεσε το Stemming (Περιστολή) με τον αλγόριθμο Porter Stemmer, ώστε τα tokens να επιστρέψουν στην αρχική τους ετυμολογική ρίζα.

Word2Vec

Δημιουργήθηκε η κλάση Word2VecVectorizer, η οποία μετατρέπει τα κείμενα σε διανύσματα (αριθμούς), χρησιμοποιώντας την σημασιολογική αξία των λέξεων, αντί για απλή καταμέτρηση. Παρακάτω, ακολουθεί μια μικρή ανάλυση για τα Word Embeddings και το Mean Pooling.

Word Embeddings: Χρησιμοποιεί τη βιβλιοθήκη Gensim για να εκπαιδεύσει ένα μοντέλο Word2Vec πάνω στα δεδομένα μας. Κάθε λέξη αντιστοιχίζεται σε ένα διάνυσμα (π.χ. 100 διαστάσεων). Λέξεις με παρόμοια έννοια (π.χ. "good", "great") αποκτούν κοντινά διανύσματα στον χώρο.

Sentence Embedding (Mean Pooling): Το Word2Vec δίνει διανύσματα για λέξεις. Εμείς θέλουμε διάνυσμα για ολόκληρο το κείμενο. Η κλάση παίρνει τον μέσο όρο (mean) των διανυσμάτων όλων των λέξεων του κειμένου. Αυτό δημιουργεί ένα μοναδικό διάνυσμα που αντιπροσωπεύει το «μέσο νόημα» του κειμένου.

Scaling (MinMaxScaler): Ο αλγόριθμος Naïve Bayes δεν μπορεί να διαχειριστεί αρνητικές τιμές εισόδου. Επειδή το Word2Vec παράγει και αρνητικούς αριθμούς, η κλάση χρησιμοποιεί τον MinMaxScaler για να μετατρέψει όλες τις τιμές στο διάστημα [0, 1].

Εκπαίδευση μοντέλων και Cross Validation

Υλοποιήθηκαν 5 διαφορετικοί συνδυασμοί μοντέλων (Pipelines), όπως ζητείται στην εργασία. Αρχικά, θα περιγράψουμε με συντομία την τεχνική Cross Validation, που χρησιμοποιήθηκε για τον κατάλληλο διαμοιρασμό των δεδομένων μας.

K-Fold Cross Validation

Με την τεχνική αυτή, μπορούμε να χωρίσουμε το σύνολο των δεδομένων μας σε K κομμάτια (folds), εκ των οποίων τα K-1 θα χρησιμοποιούνται σε κάθε επανάληψη ως train sets (δεδομένα εκπαίδευσης των μοντέλων) και το 1 τελευταίο θα χρησιμοποιείται ως test set (δεδομένα ελέγχου για την απόδοση του κάθε μοντέλου). Με αυτό τον τρόπο διαχωρισμού, εξασφαλίζουμε ότι κάθε δείγμα των δεδομένων, θα χρησιμοποιηθεί ακριβώς μία φορά για έλεγχο, στις K φορές επανάληψης.

Pipelines και Εκπαίδευση

1. Multinomial NB & Binary

   Σε αυτό το Pipeline, χρησιμοποιείται ο Multinomial Naïve Bayes ως ο ταξινομητής (classifier), όπου μετράει την δεσμευμένη πιθανότητα κάθε λέξη να ανήκει σε μία από τις δύο κατηγορίες του προβλήματος μας. Για την αναπαράσταση (Vectorizer) χρησιμοποιείται ο αλγόριθμος CountVectorizer, όπου μετράει την συχνότητα εμφάνισης κάθε λέξης στο κείμενο. Λέξεις που επαναλαμβάνονται συχνά αλλά δεν έχουν νόημα, μπορεί να κυριαρχήσουν στην τελική αξιολόγηση.

2. Multinomial NB & TF-IDF

   Στο 2ο Pipeline, χρησιμοποιείται πάλι ο Multinomial Naïve Bayes ως ο classifier και ως Vectorizer, ο TF-IDF. Η διαφορά σε σχέση με το προηγούμενο Pipeline, είναι ότι ο TF-IDF δεν υπολογίζει μόνο την συχνότητα εμφάνισης του όρου στο κείμενο αλλά σταθμίζει (εδώ αναλαμβάνει το Inverse Document Frequency) αυτήν την συχνότητα με βάση το πόσο σπάνια είναι η λέξη στο σύνολο των δεδομένων. Μειώνει

την σημασία των λέξεων που εμφανίζονται πολύ συχνά και αυξάνει την σημασία αυτών που εμφανίζονται σπάνια.

3. Bernoulli NB & Binary
   Στο 3ο Pipeline, χρησιμοποιείται ως Vectorizer ο CountVectorizer, με την διαφορά ότι έχει οριστεί σε binary, δηλαδή να μην μετράει την συχνότητα εμφάνισης του κάθε όρου αλλά μόνο την ύπαρξη του ή όχι. Αν ένας όρος υπάρχει, τότε αντιστοιχίζεται με το 1, αλλιώς με το 0. Ο classifier Bernoulli Naïve Bayes, υπολογίζει τις δεσμευμένες πιθανότητες, λαμβάνοντας υπ' όψιν και τις λέξεις που απουσιάζουν από το κείμενο.

4. Boolean(Binarized) Multinomial NB & Binary
   Στο 4ο Pipeline, Vectorizer είναι πάλι ο CountVectorizer με binary αναπαράσταση, ώστε να μετράει μόνο την ύπαρξη του όρου στο κείμενο. Στον classifier έχει οριστεί ο Boolean Multinomial Naïve Bayes, ο οποίος δουλεύει με τον ίδιο τρόπο που δουλεύει ο Multinomial Naïve Bayes, με την διαφορά ότι λαμβάνει δυαδικά δεδομένα, δηλαδή υπολογίζει τις δεσμευμένες πιθανότητες για τους όρους, χωρίς όμως να μετράει και την συχνότητα εμφανίσεων, παρά μόνο την ύπαρξη (0 ή 1).

5. Multinomial NB & Word2Vec
   Στο 5ο και τελευταίο Pipeline, classifier είναι ο Multinomial Naïve Bayes, ενώ ο Vectorizer είναι ο Word2Vec. Για την αναπαράσταση αυτή, κάθε λέξη γίνεται διάνυσμα (π.χ. 100 αριθμών) και το κείμενο αναπαρίσταται ως ο μέσος όρος (Mean Pooling) των διανυσμάτων των λέξεων του. Ύστερα, εφαρμόζεται κανονικοποίηση στο διάστημα [0,1] με τον MinMax Scaler, καθώς ο Naïve Bayes δεν δέχεται αρνητικές τιμές.

Πειραματικά Αποτελέσματα του Μέρους Α

Σε αυτήν την ενότητα, θα παρουσιαστούν τα αποτελέσματα από την εκπαίδευση των μοντέλων και θα γίνει αξιολόγηση με βάση μετρικές Ταξινόμησης (Accuracy, Precision, Recall, F1).

Τα αποτελέσματα βρίσκονται και εσωτερικά του κώδικα αλλά και σε εξωτερικό αρχείο Excel που παρήχθη μέσω του κώδικα.

Πίνακας με μετρικές αξιολόγησης και για τα 5 μοντέλα

	Accuracy	Precision	Recall	F1-Score
K3_E1 (Bin MNB + Binary)	0,8195	0,82010407	0,8195	0,81943076
K1_E3 (MNB + TF-IDF)	0,813	0,8140209	0,813	0,81284244
K1_E2 (MNB + Counts)	0,808	0,80864083	0,808	0,80791692
K2_E1 (Bernoulli + Binary)	0,7905	0,80123624	0,7905	0,78856569
K1_E4 (MNB + Word2Vec)	0,565	0,56507186	0,565	0,56478381

<u>Σχολιασμός</u>

Τα μοντέλα έχουν καταταχθεί με φθίνουσα σειρά από το καλύτερο προς το χειρότερο. Τα αποτελέσματα δείχνουν πως το 4ο Pipeline μας πέτυχε το υψηλότερο σκορ σε όλες τις μετρικές και άρα κατατάσσεται πρώτο σε σύγκριση με τα υπόλοιπα 4. Συγκεκριμένα, η Ορθότητα (Accuracy) είναι σε ποσοστό 81,95% και το F1 Score είναι επίσης στο ίδιο ποσοστό 81,94%. Στα ίδια ποσοστά κυμαίνονται επίσης και οι υπόλοιπες 2 μετρικές (Precision, Recall).

Μπορούμε να σχολιάσουμε πως η Δυαδική Πληροφορία, έπαιξε πολύ σημαντικό ρόλο στο αποτέλεσμα αυτό, και πως η συχνότητα εμφάνισης δεν έχει απαραίτητα την σημαντικότερη πληροφορία.

Στην δεύτερη θέση κατατάσσεται το 2ο Pipeline που αναπτύχθηκε, με πολύ μικρή διαφορά από το 4ο Pipeline. Συγκεκριμένα, με Accuracy Score = 81,3% και F1 Score = 81,2%. Το Accuracy είναι μια πρώτη ένδειξη για το μοντέλο, ωστόσο κοιτάμε και το F1, όπου είναι ο αρμονικός μέσος όρος των Precision και Recall, ώστε να βεβαιωθούμε πως η Ακρίβεια και η Ανάκληση είναι σε υψηλά επίπεδα.

Η βαρύτητα που δίνει η μέτρηση TF-IDF και πιο συγκεκριμένα το IDF, φαίνεται πως αποδίδει ιδιαιτέρως. Αποδεικνύεται, πως οι σπανιότερες λέξεις έχουν μεγαλύτερη σημασία.

Τελευταίο μοντέλο κατατάχθηκε το 5° Pipeline. Η διαφορά με τα υπόλοιπα μοντέλα και στις 4 μετρικές είναι εμφανής. Με Accuracy Score = 56,5% και F1 Score = 56,4%, αποδεικνύει ότι η τεχνική Word2Vec για αυτό το πρόβλημα είναι η χειρότερη επιλογή. Αυτό ίσως να οφείλεται στο γεγονός ότι, 2000 κείμενα μπορεί να μην είναι επαρκή για την εκπαίδευση του μοντέλου, με αποτέλεσμα τα παραγόμενα embeddings να μην έχουν υψηλή σημασιολογική ποιότητα. Επίσης, με το Mean Pooling, δηλαδή με την λήψη του μέσου όρου όλων των λέξεων των κειμένων, ενδεχομένως να «εξουδετερώνεται» το συναίσθημα των λέξεων. (π.χ. τα διανύσματα των «good» και «bad» μπορεί να αλληλοαναιρεθούν)

Γλωσσική προεπεξεργασία και Baseline

Στην ενότητα αυτή, θα αναλυθούν συνοπτικά οι 3 τεχνικές γλωσσικής προεπεξεργασίας για το Β' Μέρος της εργασίας. Ύστερα, θα γίνει σύγκριση της απόδοσης με τα μοντέλα Naïve Bayes που περιεγράφησαν παραπάνω.

Διαχείριση Άρνησης (Negation)

Όταν συναντάμε λέξεις άρνησης στο κείμενο (όπως: not, no, never, n't, cannot, nothing, nowhere), τότε σε κάθε επόμενη λέξη προσθέτουμε το πρόθεμα «NOT_» μέχρι να βρούμε κάποιο σημείο στίξης. Με αυτόν τον τρόπο, κάνουμε πιο έκδηλη την ύπαρξη αρνητικότητας στο κείμενο.

POS (Part-Of-Speech tag)

Ανάλογα τι μέρος του λόγου είναι κάθε λέξη (π.χ. ουσιαστικό, επίθετο, επίρρημα) δίνεται και ένα αντίστοιχο βάρος στην λέξη αυτή. Επειδή, στην περίπτωση μας θέλουμε να κάνουμε Ανάλυση Συναισθήματος, τα επίθετα και τα επιρρήματα θα έχουν μεγαλύτερο βάρος από τις υπόλοιπες λέξεις. Αν θεωρήσουμε πως, όλες οι λέξεις έχουν βάρος 1, τότε τα επίθετα και τα επιρρήματα θα έχουν βάρος 2.

Στάθμιση Θέσης (Position Weighting)

Στις κριτικές κειμένου, συχνά η περίληψη της άποψης (sentiment summary) βρίσκεται στην αρχή (πρόλογος) ή στο τέλος (συμπέρασμα) του κειμένου, ενώ το κύριο μέρος περιέχει περιγραφή πλοκής. Για αυτό και η 1η και η τελευταία πρόταση του κειμένου, προστίθενται ξανά, στο τέλος του κειμένου.

Πειραματικά Αποτελέσματα του Μέρους Β

Πίνακας με μετρικές αξιολόγησης για τα 5 μοντέλα με το Baseline μοντέλο να είναι ο Multinomial NB

A	B	C	D	E
	Accuracy	**Precision**	**Recall**	**F1-Score**
3. Baseline + POS Weighting	0,8325	0,833062343	0,8325	0,83242584
5. Baseline + ALL Combined	0,8245	0,824906591	0,8245	0,824446982
4. Baseline + Position Weighting	0,82	0,820511013	0,82	0,819931209
2. Baseline + Negation	0,8185	0,819041282	0,8185	0,818423011
1. Baseline (Simple Clean)	0,811	0,811607616	0,811	0,810917586

<u>Σχολιασμός</u>

Αρχικά, επισημαίνεται ότι και στο μέρος Β, εφαρμόστηκε 5-Fold Cross Validation, όπως στο μέρος Α, για την εκπαίδευση των μοντέλων. Τα αποτελέσματα, αφορούν τις 3 παραπάνω τεχνικές γλωσσικής προεπεξεργασίας του μέρους Β, και το Baseline μοντέλο είναι ο Multinomial Naïve Baye, διότι αυτό αποδείχθηκε ως το καλύτερο, από τα πειραματικά αποτελέσματα του μέρους Α.

Βλέπουμε ότι στην 1η θέση, κατατάσσεται το Baseline μαζί με το Part-Of-Speech Weighting. Με Accuracy Score = 83,25% και F1 Score = 83,24% πετυχαίνει την υψηλότερη βαθμονόμηση και έχει εξαιρετική απόδοση και στις 4 μετρικές. Φαίνεται, ότι η απόδοση διπλάσιου βάρους στα επίθετα και στα επιρρήματα, λειτούργησε υπέρ μας. Είναι λογικό, καθώς στην Ανάλυση Συναισθήματος, καθοριστικό ρόλο παίζουν κατά κύριο λόγο τα επίθετα.

Και τα υπόλοιπα μοντέλα, πέτυχαν εξίσου καλές μετρήσεις και έχουν απειροελάχιστη διαφορά με το μοντέλο της 1ης θέσης.

Τελευταίο, κατατάχθηκε το μοντέλο Baseline (Simple Clean), που είναι ουσιαστικά ο Multinomial Naïve bayes πάνω στα «καθαρά» δεδομένα, δηλαδή στα κείμενα που προέκυψαν μετά την επεξεργασία των δεδομένων στο Μέρος Α. Έχει πολύ μικρή διαφορά από το Baseline + POS Weighting, συγκεκριμένα με Accuracy Score = 81,1% και F1 Score = 81,09%. Και πάλι, ωστόσο είναι εξίσου καλό μοντέλο για τις ανάγκες της εργασίας μας.

Μπορούμε να σχολιάσουμε πως οι 3 τεχνικές γλωσσικής προεπεξεργασίας του Μέρους Β, αποδίδουν καλύτερα από αυτές του Μέρους Α και θα ήταν προτιμότερο να βασιστούμε σε αυτές. Εξάλλου, είναι πιο στοχευμένες στην

Ανάλυση Συναισθήματος και άρα είναι καταλληλότερες για το πρόβλημα μας και τα δεδομένα, που έχουμε. Οι τεχνικές του Μέρους Α, είναι τεχνικές που χρησιμοποιούνται γενικότερα για την προεπεξεργασία φυσικής γλώσσας, σε πάσης φύσεως κείμενα. Εδώ έχουμε ένα πιο συγκεκριμένο πρόβλημα, οπότε συνίσταται να χρησιμοποιούμε τις τεχνικές του Μέρους Β.

Σύγκριση με το RapidMiner

Αυτήν η ενότητα είναι η τελική και συγκρίνει τα αποτελέσματα του Μέρους Α (μόνο για τις τεχνικές με Binary, TF, TF-IDF αναπαράσταση και Multinomial NB) με το εργαλείο RapidMiner για τις αντίστοιχες τεχνικές αναπαράστασης. Παρατίθενται, 3 εικόνες από το PerformanceVector του RapidMiner.

PerformanceVector για την Binary Αναπαράσταση

PerformanceVector

```
PerformanceVector:
accuracy: 66.70% +/- 2.08% (micro average: 66.70%)
ConfusionMatrix:
True:   pos     neg
pos:    669     335
neg:    331     665
weighted_mean_recall: 66.70% +/- 2.08% (micro average: 66.70%), weights: 1, 1
ConfusionMatrix:
True:   pos     neg
pos:    669     335
neg:    331     665
weighted_mean_precision: 66.74% +/- 2.10% (micro average: 66.70%), weights: 1, 1
ConfusionMatrix:
True:   pos     neg
pos:    669     335
neg:    331     665
```

<u>Σχολιασμός</u>

Βλέπουμε, πως υπάρχει πολύ μεγάλη απόκλιση των 3 μετρικών για την Binary Αναπαράσταση του RapidMiner σε σχέση με το μοντέλο που αναπτύξαμε στον κώδικα. Οι μετρικές για το μοντέλο του κώδικα είναι: Accuracy Score = 81,95%, Precision = 82,01%, Recall = 83,25%. Οι αποκλίσεις είναι σημαντικές και προφανώς δεν είναι κατάλληλο να χρησιμοποιήσουμε το RapidMiner για αυτό το πρόβλημα, με αυτά τα

δεδομένα που έχουμε. Σημειώνεται, ότι στο RapidMiner εφαρμόστηκαν οι ίδιες τεχνικές γλωσσικής προεπεξεργασίας, όπως στο Μέρος Α. Όσον αφορά, τον Confusion Matrix βλέπουμε πως τα FP (False Positives) και τα FN (False Negatives) είναι 335 και 331, αντίστοιχα. Είναι αρκετά υψηλά και τα δύο και σκοπός είναι πάντα σε προβλήματα Classification, να ελαχιστοποιούμε τα FP και FN.

PerformanceVector για την TF(Counts) Αναπαράσταση

PerformanceVector

```
PerformanceVector:
accuracy: 69.70% +/- 2.20% (micro average: 69.70%)
ConfusionMatrix:
True:   pos     neg
pos:    697     303
neg:    303     697
weighted_mean_recall: 69.70% +/- 2.20% (micro average: 69.70%), weights: 1, 1
ConfusionMatrix:
True:   pos     neg
pos:    697     303
neg:    303     697
weighted_mean_precision: 69.72% +/- 2.20% (micro average: 69.70%), weights: 1, 1
ConfusionMatrix:
True:   pos     neg
pos:    697     303
neg:    303     697
```

<u>Σχολιασμός</u>

Βλέπουμε, πως υπάρχει πάλι πολύ μεγάλη απόκλιση των 3 μετρικών για την Counts – TF(Term Frequency) Αναπαράσταση του RapidMiner σε σχέση με το μοντέλο που αναπτύξαμε στον κώδικα. Οι μετρικές για το μοντέλο του κώδικα είναι: Accuracy Score = 80,8%, Precision = 80,86%, Recall = 80,8%. Και εδώ, καταλήγουμε πως το RapidMiner δεν είναι κατάλληλο για αυτό το πρόβλημα με αυτό το συγκεκριμένο μοντέλο.

PerformanceVector για την TF-IDF Αναπαράσταση

PerformanceVector

```
PerformanceVector:
accuracy: 67.85% +/- 3.38% (micro average: 67.85%)
ConfusionMatrix:
True:   pos     neg
pos:    696     339
neg:    304     661
weighted_mean_recall: 67.85% +/- 3.38% (micro average: 67.85%), weights: 1, 1
ConfusionMatrix:
True:   pos     neg
pos:    696     339
neg:    304     661
weighted_mean_precision: 67.91% +/- 3.41% (micro average: 67.87%), weights: 1, 1
ConfusionMatrix:
True:   pos     neg
pos:    696     339
neg:    304     661
```

Σχολιασμός

Βλέπουμε, πως υπάρχει και εδώ πολύ μεγάλη απόκλιση των 3 μετρικών για την TF-IDF Αναπαράσταση του RapidMiner σε σχέση με το μοντέλο που αναπτύξαμε στον κώδικα. Οι μετρικές για το μοντέλο του κώδικα είναι: Accuracy Score = 81,3%, Precision = 81,4%, Recall = 81,3%. Και εδώ, καταλήγουμε πως το RapidMiner δεν είναι κατάλληλο για αυτό το πρόβλημα με αυτό το συγκεκριμένο μοντέλο.

Συμπεράσματα

Μπορούμε με βάση αυτές τις 3 εικόνες, που προέκυψαν από την εκτέλεση του μοντέλου στο πρόγραμμα RapidMiner, να καταλήξουμε στο συμπέρασμα πως τα μοντέλα που αναπτύχθηκαν στο κώδικα, μπορούν και αποδίδουν πολύ καλύτερα, καθώς είναι πιο στοχευμένα στην επεξεργασία των δεδομένων που τους δόθηκαν, και τα αποτελέσματα έδειξαν πως πετυχαίνουν υψηλά σκορ σε όλες τις μετρικές. Στο RapidMiner δεν είχαμε υπερβολικά χαμηλά σκορ, απλώς εφόσον αναπτύχθηκε κώδικας που απέδιδε καλύτερα, τότε είναι προτιμότερο να εμπιστευτούμε τον κώδικα. Οι μετρικές των μοντέλων του κώδικα, για τα περισσότερα μοντέλα, πέτυχαν Accuracy και F1 άνω του 80%, γεγονός που δείχνει μεγάλη αξιοπιστία.

Αναφορές σε ιστοτόπους - Βιβλιογραφία

1. https://en.wikipedia.org/wiki/Sentiment_analysis